

AI Model Training for AD L4 Robotaxi Systems

Ho Chi Minh City University of Technology (HCMUT)
Vietnam National University Ho Chi Minh City, Ho Chi Minh City, Vietnam

June 18th 2026

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA

Nội dung World Model

- 1 Công việc đang thực hiện
- 2 Kế hoạch tiếp theo

Công việc đang thực hiện

Luồng hoạt động của V-JEPA2

- **Input:** một đoạn video ngắn (16-64 frame, fps=16) sử dụng duy nhất Front Camera
- **Pre-processing:** Patchification & Masking
 - Patchification
 - Video đầu vào được biểu diễn dưới dạng tensor 4D ($T \times C \times W \times H$).
 - Video được chia thành 3D tubelets ($2 \times 16 \times 16$) từ cặp khung hình I_t và I_{t+1} , chứa thông tin không gian và thời gian
 - Random Masking
 - Một tỷ lệ lớn các 3D patches được che ngẫu nhiên (thường 60%-90%).
 - Các patch còn nhìn thấy tạo thành Context ($x_{context}$) và patch bị che tạo thành Target (x_{target}).
 - Mục đích: Context được dùng để dự đoán đặc trưng của Target, buộc model phải học cách suy luận và dự đoán từ thông tin hạn chế

Công việc đang thực hiện

- **Visual Encoder:**

- Chức năng: Xử lý các patch không bị che và dùng 3D Rotary Position Embedding để mã hóa thông tin cả không - thời gian
- Quy trình: Nhận tubelet visible ($P \times P \times T$) và biến đổi chúng thành embedding features (thường chiều dài 768 hoặc 1024)
- Output: Tập hợp các embedding vectors đại diện những gì model nhìn thấy.

- **Predictor:**

- Chức năng: Nhận embedding features từ phần visible do Encoder tạo ra và thông tin vị trí của các patch bị che để dự đoán embedding features của các masked patch
- Quy trình: Sử dụng cơ chế attention để suy luận từ ngữ cảnh visible để sinh ra dự đoán cho masked regions.
- Output: Tập hợp các embedding vectors dự đoán cho phần bị che.


Công việc đang thực hiện

- **Output:** Sinh ra feature embedding từ Encoder và khả năng dự đoán tương lai từ Predictor:
 - Thông tin về đối tượng (objects).
 - Chuyển động (motion) theo thời gian.
 - Quan hệ giữa các đối tượng trong cảnh.
 - Ngữ cảnh không gian – thời gian (spatio-temporal context).

Công việc đang thực hiện

Kết quả đánh giá không gian - Cosine Similarity

Vùng đỏ hoặc ấm ứng với cosine thấp, tức là nơi mô hình tái tạo kém (ngữ cảnh lạ), còn vùng xanh là nơi tái tạo tốt (mean càng cao càng tốt)




Vinfast

OpenScene



Dữ liệu thu thập



Công việc đang thực hiện

Kết quả đánh giá không gian - Mahalanobis Distance


Vùng đỏ ứng với residual nằm xa phân phối OS nên mức OOD cao; giá trị được chuẩn hóa min-max theo từng ảnh, do đó chỉ nên so sánh trong phạm vi một ảnh (càng thấp càng tốt)



Vinfast



OpenScene




Dữ liệu thu thập

Công việc đang thực hiện

Kết quả đánh giá thời gian - Predictor Loss và Mutual Information

- Chia thành các tình huống: *Động lực học dị biệt, Lấn làn/tạt đầu, Nhiễu Loạn môi trường (do thời tiết)*
- Đặc điểm:
 - Tần suất Loss Spikes dày đặc tại các thời điểm quan trọng
 - Spike cục bộ với Predictor Loss trung bình cao hoặc Temporal Cosine Similarity gần bằng 1
- Phân tích: Mô hình dự đoán trạng thái tương lai thất bại chính tại thời điểm va chạm hoặc khi phương tiện cắt ngang đột ngột, chứng minh mô hình thiếu khả năng dự đoán các tình huống động lực học phức tạp ngoài dữ liệu huấn luyện.

Công việc đang thực hiện




Khoảng giây thứ 30 xảy ra va chạm

Công việc đang thực hiện



Spike Loss ở cuối video (~10-11 giây) và MI Collapse có biến động nhưng không quá sâu.

Công việc đang thực hiện



Spike Predictor Loss 1-2 giây đầu đúng lúc xe chuyển làn đột ngột không xi-nhan
Spike MI Collapse ở ~6 giây, khi mưa nặng (hình ảnh mờ, nhiều đồng nhất) và biển báo (mờ do nước) thể hiện mô hình không extract được đặc trưng đa dạng

Kế hoạch tiếp theo

- Tiếp tục hoàn thiện việc đánh giá không - thời gian
- Tiền xử lý dữ liệu thu thập được

THANK YOU FOR LISTENNING!