BÁO CÁO TIẾN ĐỘ NGHIÊN CỨU VÀ KẾ HOẠCH TRIỂN KHAI THỰC TẾ

Mục lục

1 Thích nghi nhận thức cho V-JEPA trên dữ liệu giao thông Việt Nam 3
1.1 Mục tiêu 3
1.2 Thiết lập thực nghiệm ban đầu 3
1.3 Phương pháp phân tích 3
1.4 Kết quả định tính ban đầu 4
1.5 Đề xuất cấu hình Masking Strategy 4

2 Xử lý Dữ liệu và Đánh giá Môi trường Lập kế hoạch 5
2.1 Mục tiêu và Hiện trạng Dữ liệu 5
2.2 Khoảng trống yêu cầu so với Tiêu chuẩn NAVSIM 5
2.3 Đánh giá Hướng tiếp cận xử lý dữ liệu 6
2.4 Kết luận & Lộ trình Đề xuất 7

1 Thích nghi nhận thức cho V-JEPA trên dữ liệu giao thông Việt Nam

1.1 Mục tiêu

Mục tiêu của phần này là đánh giá khả năng thích nghi của Encoder V-JEPA (tiền huấn luyện trên dữ liệu quốc tế) khi áp dụng vào bối cảnh giao thông Việt Nam, nơi có:

- mật độ xe máy cao,
- vật thể nhỏ xuất hiện dày đặc,
- che khuất và chuyển động phức tạp.

Trọng tâm là kiểm tra liệu mô hình có học được đặc trưng của vật thể nhỏ hay ưu tiên quá mức các cấu trúc vĩ mô (mặt đường, bầu trời, kiến trúc lớn).

1.2 Thiết lập thực nghiệm ban đầu

- Mô hình: `facebook/vjepa2-vitl-fpc64-256` (Hugging Face, backend HF-only).
- Dữ liệu: video giao thông VF đã chuẩn hóa về luồng frame phù hợp để probe.
- Cấu hình cửa sổ thời gian: `clip_len=8`, `clip_stride=8` (hoặc `stride=4` trong một số thử nghiệm).
- Visualization chính: **Token Heatmap**, **Occlusion Sensitivity**, **PCA token-space**.

1.3 Phương pháp phân tích

Token Heatmap Token heatmap được tính từ chuẩn vector token theo lưới patch tại thời điểm quan sát:

$$H_{i,j} = \|z_{i,j}\|_2$$

Trong đó $z_{i,j}$ là embedding token tại patch (i, j). Heatmap thể hiện *cường độ biểu diễn*, không trực tiếp khẳng định quan hệ nhân quả.

Occlusion Sensitivity Với mỗi vùng che khuất R, thay vùng đó bằng giá trị trung bình và đo độ thay đổi embedding clip:

$$S(R) = 1 - \cos\big(f(x), f(x \odot \bar{R})\big)$$

Trong đó $f(\cdot)$ là embedding clip từ encoder. $S(R)$ càng lớn, vùng R càng quan trọng đối với biểu diễn của mô hình.

PCA trên token Token tại một tubelet được chiếu về không gian thành phần chính:

$$Y = (Z - \mu)\, W_k$$

với W_k là k trục chính đầu tiên (thực nghiệm dùng $k = 3$). PCA giúp quan sát cấu trúc cụm đặc trưng (đường, vật thể chuyển động, nền cảnh).

1.4 Kết quả định tính ban đầu

Quan sát trên nhiều clip thử nghiệm cho thấy:

- Mô hình phản ứng tốt với đặc trưng quy mô lớn như mặt đường, vùng trời, bố cục phối cảnh.
- Độ nhạy với vật thể nhỏ (xe máy, người đi bộ xa) còn hạn chế; các thực thể nhỏ thường bị trộn vào nền trong biểu diễn.
- Occlusion map ở cấu hình lưới thô cho tín hiệu nổi bật ở vùng trung tâm đường nhiều hơn vùng vật thể nhỏ.
- PCA cho thấy khả năng tách cụm cơ bản theo cấu trúc cảnh, nhưng chưa ổn định cho nhóm đối tượng nhỏ, dày và che khuất.

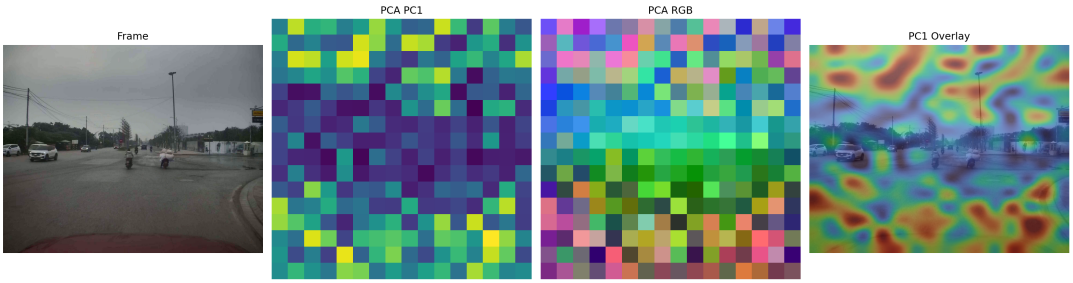

Hình 1: Phân tích PCA token-space trên dữ liệu VF

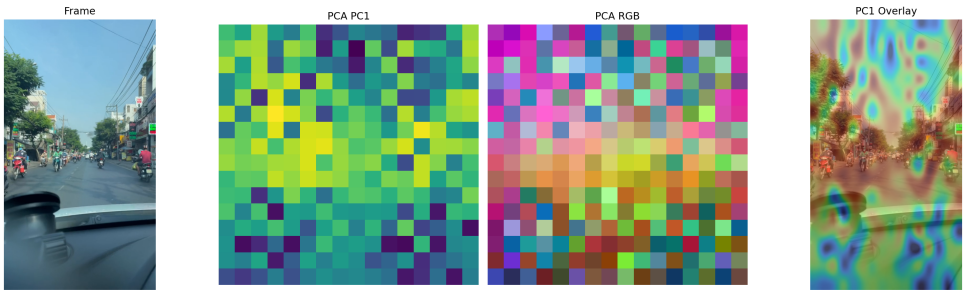

Hình 2: Kết quả visualization trong bối cảnh mật độ xe máy cao

1.5 Đề xuất cấu hình Masking Strategy

> **Giả thuyết:** Phân phối dữ liệu tiền huấn luyện chưa bao phủ đủ các tình huống xe máy dày, vật thể nhỏ và che khuất kiểu Việt Nam; do đó encoder có xu hướng ưu tiên tín hiệu vĩ mô và làm suy giảm độ phân giải ngữ nghĩa của đối tượng nhỏ.

Để ép mô hình học đặc trưng tồn tại của vật thể nhỏ, đề xuất fine-tune theo lộ trình:

- Sweep **spatial masking scale** theo 3 mức: nhẹ, trung bình, mạnh.
- Giảm kích thước patch hiệu dụng hoặc tăng mật độ vị trí che để tránh gộp xe máy vào nền.

- Ưu tiên masking có cấu trúc không gian-thời gian (spatio-temporal block), thay vì masking ngẫu nhiên thuần.

Cấu hình tham khảo:

- Nhẹ: `spatial_scale` $\in [0.08, 0.15]$
- Trung bình: `spatial_scale` $\in [0.15, 0.28]$
- Mạnh: `spatial_scale` $\in [0.28, 0.45]$

Tiêu chí đánh giá cho vòng tiếp theo:

- Tăng độ tập trung occlusion vào vùng chứa vật thể nhỏ (xe máy/người đi bộ).
- PCA tách cụm rõ hơn giữa nền đường và đối tượng chuyển động nhỏ.
- Tính nhất quán giữa nhiều clip và nhiều điều kiện giao thông (thoáng, đông, che khuất).

Vì thử nghiệm ban đầu xác nhận tồn tại **domain gap** ở mức biểu diễn: V-JEPA hiện thiên về đặc trưng vĩ mô và chưa đủ nhạy với đối tượng nhỏ trong bối cảnh giao thông Việt Nam. Nên hướng cải thiện khả thi nhất là can thiệp trực tiếp vào **masking strategy** trong fine-tune để buộc encoder học đặc trưng của vật thể nhỏ.

2 Xử lý Dữ liệu và Đánh giá Môi trường Lập kế hoạch

2.1 Mục tiêu và Hiện trạng Dữ liệu

Đánh giá khả năng sử dụng tập dữ liệu hiện tại của VinFast (VF) để vận hành môi trường giả lập NAVSIM, phục vụ cho Giai đoạn 2 của Drive-JEPA (Distillation & Chấm điểm EPDMS nhằm học hành vi lái xe). Dựa trên tập sample hiện tại, hiện trạng ghi nhận:

- **Hình ảnh (Camera):** Dữ liệu từ 1 camera (`CAM_P_F` - dự kiến camera trước), lưu định dạng `.jpg`.
- **LiDAR:** đám mây điểm 3D quét 360 độ lưu dưới dạng nén `.laz`.
- **Dữ liệu hành trình (Ego/Vehicle):** Các file CSV (NAV, IMU, STEER) rời rạc, chênh lệch timestamp lớn so với cảm biến ảnh/lidar.
- **Calibration & Annotation:** Chưa có.

2.2 Khoảng trống yêu cầu so với Tiêu chuẩn NAVSIM

Để NAVSIM hoạt động và đánh giá được các tiêu chí EPDMS, hệ thống đòi hỏi một cấu trúc dữ liệu khắt khe đã được đóng gói chuẩn hóa (file `navsim_logs/*.pkl`). Hiện tại, dữ liệu VF thiếu hụt 4 mảng trọng yếu nhất:

- **Camera Calibration:** Thiếu ma trận nội thông *intrinsics* (fx, fy, cx, cy) và ngoại thông *extrinsics* (sensor2lidar_rotation/translation). Nếu không có intrinsics, không thể map điểm 3D sang pixel 2D ảnh. Nếu không có extrinsics, các box LiDAR chỉ đứng đúng trong không gian BEV/LiDAR mà không thể overlay chính xác lên hình ảnh.

- **Đồng bộ hóa Ego Pose:** Dữ liệu định vị cập nhật thưa thớt (lệch nhiều giây). NAVSIM bắt buộc mỗi frame ảnh phải đi kèm một tọa độ Global Pose chính xác. *Khi nguồn gốc có log 30Hz, việc này có thể khắc phục bằng cách đồng bộ theo frame.*
- **Nhãn 3D (3D Bounding Boxes):** Không có nhãn Ground Truth về kích thước, tọa độ, và vận tốc (`gt_boxes`, `gt_velocity_3d`).
- **Bản đồ HD (HD Maps):** Dữ liệu VF không đi kèm dữ liệu bản đồ vector tĩnh (định dạng `.db` của nuPlan) để đánh giá lấn làn hay vượt đèn đỏ.

2.3 Đánh giá Hướng tiếp cận xử lý dữ liệu

Phương pháp BEV chỉ khả thi ở mức bootstrap (dựng top-down box thô từ LiDAR) nhưng chưa đủ cho NAVSIM chuẩn vì:

- Thiếu thông số Camera Extrinsics nên không thể chiếu ảnh camera sang BEV grid chính xác.
- Hệ thống BEV chuẩn cần nhiều camera bao quanh để tạo góc nhìn rộng; hiện tại chỉ có 1 luồng camera.
- Thiếu Ground Truth 3D chuẩn để huấn luyện/chấm điểm theo pipeline NAVSIM.

> **Thực nghiệm trích xuất Box 3D bằng LiDAR-first:** Do thiếu Camera Calibration, nhận diện 3D từ ảnh bị đình trệ. Em có thử nghiệm dùng dữ liệu LiDAR để xuất bounding box: Script đọc trực tiếp file `.laz`, áp dụng bộ lọc triệt tiêu mặt đất và dùng thuật toán **DBSCAN clustering** để gom cụm mây điểm. Dù giúp khởi tạo vùng đối tượng không phụ thuộc Camera, kết quả xuất ra chỉ là hộp giới hạn thô (coarse boxes) chưa có nhãn ngữ nghĩa, hiệu quả hiện tại chưa khả quan. Em đang xem lại phương pháp này và tìm hiểu cách khác có thể nhận diện tốt hơn.

Hình 3: Áp dụng dữ liệu LIDAR đưa ra bounding box

Yêu cầu NAVSIM	Thực trạng dữ liệu VF	Trạng thái
Camera Calibration	Thiếu Intrinsics, Extrinsics, Distortion	**BLOCKER**
Ego Global Pose	NAV/IMU còn thưa (Có thể nội suy khi đầy đủ log gốc đạt với 30Hz)	
3D Annotations	Không có `gt_boxes`, `gt_velocity_3d`	**MISSING**
HD Maps	Không có dữ liệu định dạng SQLite (.db)	**MISSING**
Driving Command	Chưa có ontology/mapping lệnh lái	**PARTIAL**
Lidar Format	Định dạng `.laz` (Cần đổi sang `.pcd`)	**CONVERTIBLE**

2.4 Kết luận & Lộ trình Đề xuất

Tập dữ liệu hiện tại chưa đủ điều kiện để chạy trực tiếp môi trường NAVSIM cho quy trình Planning (Giai đoạn 2). Thay vì ép buộc dữ liệu vào chuẩn khắt khe, lộ trình tiếp theo được điều chỉnh như sau:

1. **Sử dụng Dummy Map:** Mượn một bản đồ có sẵn của nuPlan và tạm thời dùng map chuẩn hóa trong môi trường giả lập để phục vụ phát triển pipeline của framework khi cần thiết lập pipeline. Tuy nhiên đây là bước quan trọng trong dữ liệu, ngoài ra em có nghe phía VF rằng họ vẫn đang chuẩn bị dữ liệu bổ sung.

2. **Khai thác CARLA cho Simulation Bootstrap:** Thay vì phụ thuộc hoàn toàn vào dữ liệu VF để dựng môi trường, có thể sử dụng CARLA như một simulator độc lập để khởi tạo pipeline Planning.

   - CARLA tự cung cấp map (OpenDRIVE), sensor setup (camera, LiDAR, IMU), calibration và traffic, do đó không yêu cầu dữ liệu VF để chạy môi trường.
   - Phù hợp để kiểm thử nhanh closed-loop planning và pipeline Drive-JEPA trong môi trường chuẩn hóa.
   - Dữ liệu VF hiện tại có thể tận dụng ở mức *offline analysis* hoặc *pseudo-label bootstrap* (ví dụ từ LiDAR clustering), nhưng chưa đủ để replay chính xác trong CARLA do thiếu calibration, pose đồng bộ và annotation chuẩn.
   - Cách tiếp cận kết hợp: dùng CARLA để kiểm thử closed-loop pipeline và đánh giá hành vi lái cơ bản, trong khi dữ liệu VF đóng vai trò tham chiếu thực tế (*reference*) để đánh giá domain gap.
   - Nhược điểm là CARLA chỉ là phương pháp để test closed-loop, trajectories từ CARLA mang tính synthetic, không tương đương teacher trajectories từ dữ liệu thật VF. Ngoài ra thì việc tính điểm cũng là vấn đề lớn, Về mặt kỹ thuật có thể implement NC, DAC, EP tương tự trong CARLA, nhưng kết quả không thể so sánh với các paper khác vì data distribution khác hoàn toàn.