

BÁO CÁO NGHIÊN CỨU DỰ ÁN

Tìm kiếm Research Gap cho kiến trúc
Drive-JEPA trong Thế giới thực

Mục lục

1	Tổng quan	3
1.1	Sự chuyển dịch từ Kiến trúc Modular sang End-to-End (E2E)	3
1.2	Mô hình Thế giới (World Models) và Kiến trúc Dự đoán Tiềm ẩn (JEPA-style)	4
1.3	Nhận thức Đa phương thức và Hệ sinh thái Mô hình Nền tảng trong Đảm bảo Tính Bền vững (Robustness)	5
2	Xác định Research Gap	6
2.1	Tích hợp Nhận thức Đa phương thức (Multimodal sensor)	6
2.2	Hạn chế trong Cơ chế Chứng cất Quỹ đạo Đa phương thức	8
2.3	Mô hình hóa Động lực học Tương tác Đa tác nhân và Thách thức Định chuẩn trong Môi trường Phi cấu trúc	10
2.4	Hiệu năng Tính toán trên Thiết bị Nhúng (Edge Deployment Computing)	11

1 Tổng quan

1.1 Sự chuyển dịch từ Kiến trúc Modular sang End-to-End (E2E)

Hệ thống lái tự động (ADS) truyền thống thường được thiết kế theo kiến trúc phân tầng dạng module (Modular Pipeline), chia tách hệ thống thành các khối chức năng tuần tự độc lập bao gồm nhận thức (Perception), dự đoán (Prediction) và lập kế hoạch (Planning). Tuy nhiên, theo khảo sát toàn diện của Zhao et al. (2025) từ góc độ học sâu, phương pháp này đối mặt với hai rào cản cốt lõi về mặt hiệu suất: sự tích tụ sai số (Error Compounding) và sự không đồng nhất mục tiêu tối ưu (Objective Mismatch) [21].

Sai số từ các khối nhận diện đầu vào sẽ liên tục truyền tiếp và phóng đại qua các khối xử lý hạ lưu, dẫn đến các quyết định điều khiển sai lầm nghiêm trọng trong các tình huống thực tế nguy cấp (safety-critical scenarios). Hơn nữa, việc các module perception chỉ tập trung tối ưu hóa các chỉ số hình học học máy thuần túy như độ chính xác trung bình (mAP) tạo ra một khoảng cách lớn với mục tiêu tối thượng của hệ thống planning là đảm bảo an toàn (Safety) và sự thoải mái (Comfort) của hành khách. Việc chuyển đổi dữ liệu thô sang các biểu diễn trung gian hạn hẹp (như bounding boxes hay quỹ đạo rời rạc) cũng vô tình làm mất đi các đặc trưng ngữ cảnh đa tầng quan trọng cho việc ra quyết định tổng cục.

Để giải quyết các giới hạn vật lý của cấu trúc module, kiến trúc End-to-End (E2E) ra đời và đang trở thành hệ hình học (paradigm) chủ lưu, vận hành như một chương trình có khả năng vi phân hoàn toàn (fully differentiable) [21]. Thông qua cơ chế lan truyền ngược (backpropagation), E2E cho phép truyền bá trực tiếp và tối ưu hóa các biểu diễn đặc trưng chung (joint feature optimization) từ dữ liệu cảm biến thô (raw sensor data) xuyên suốt đến thẳng quỹ đạo đầu ra hoặc các lệnh điều khiển cấp thấp (low-level control). Tiến trình nghiên cứu tính đến giai đoạn 2025–2026 cho thấy sự tiến hóa mạnh mẽ của E2E, dịch chuyển từ các mạng CNN bám làn đơn giản thời kỳ đầu sang các kiến trúc Transformer tự chú ý (Self-attention Transformers) có khả năng xử lý đa tác vụ và học đa phương thức phức tạp [21].

Mặc dù sở hữu tiềm năng hiệu suất vượt trội nhờ tối ưu hóa toàn cầu, hệ thống E2E vẫn vấp phải những nút thắt lớn về tính giải thích (Explainability) và đặc biệt là hiện tượng nhầm lẫn nhân quả (Causal Confusion) [21]. Khi huấn luyện bắt chước trên tập dữ liệu của chuyên gia, mô hình có xu hướng học các "lối tắt" dựa trên các mối tương quan giả (spurious correlations) thay vì hiểu rõ nguyên nhân bản chất của hành vi vật lý. Một minh chứng điển hình là mô hình tự động kích hoạt lệnh giữ phanh liên tục chỉ vì nhận diện thấy vận tốc hiện tại bằng 0 (tương quan tĩnh trong lịch sử dữ liệu), thay vì thực sự phân tích lý do nhân quả đến từ tín hiệu đèn giao thông hoặc sự xuất hiện của các tác nhân cắt ngang dòng đường.

1.2 Mô hình Thế giới (World Models) và Kiến trúc Dự đoán Tiềm ẩn (JEPA-style)

Để giải quyết tính chất "hộp đen" của các mạng nơ-ron truyền thống và tối ưu hóa hiệu suất mẫu (sample efficiency), Mô hình Thế giới (World Models) được tích hợp vào hệ thống tự hành như một bộ mô phỏng nội tại của môi trường. Cơ chế này cung cấp cho xe khả năng suy luận phản thực tế (Counterfactual Reasoning) thông qua các lượt chạy thử trong tưởng tượng (imaginary rollouts) về các kịch bản tương lai có thể xảy ra ngay trong không gian trạng thái nội hàm.

Theo nghiên cứu tổng quan hệ thống của Feng et al. (2025), các trường phái thiết kế World Models hiện nay được phân loại tường minh thành một cấu trúc gồm ba tầng chiến lược [22]:

1. *Sự sinh thành thế giới vật lý tương lai (Generation of Future Physical World)*: Tập trung vào việc dự báo sự tiến hóa của phân cảnh dựa trên không gian Ảnh, không gian Bird's-Eye-View (BEV), Lưới chiếm chỗ (Occupancy Grid) hoặc Mây điểm (Point Cloud) thông qua các mô hình khuếch tán (diffusion models) hoặc dự báo occupancy 4D.
2. *Lập kế hoạch hành vi cho các tác nhân thông minh (Behavior Planning for Intelligent Agents)*: Kết hợp các thuật toán dựa trên quy tắc (rule-driven) với các paradigm học máy, tối ưu hóa bản đồ chi phí (cost map) và học tăng cường (RL) để sinh quỹ đạo.
3. *Sự tương tác giữa Dự đoán và Lập kế hoạch (Interaction between Prediction and Planning)*: Hướng tới khả năng ra quyết định cộng tác đa tác nhân và tối ưu hóa quỹ đạo khép kín dựa trên các kiến trúc tăng cường bộ nhớ.

Trong họ các mô hình không gian trạng thái tuần tự phục vụ cho các tầng kiến trúc này, hướng tiếp cận dự đoán cấu trúc tiềm ẩn (Predictive Latent Architectures) đại diện bởi JEPA thể hiện sự vượt trội về mặt triết lý vận hành so với các mô hình RSSM (Recurrent State Space Model) truyền thống [22]. Các mô hình dựa trên RSSM thường lãng phí một lượng lớn tài nguyên tính toán ở khâu giải mã (decoding stage) để tái tạo từng điểm ảnh (pixel reconstruction) của các khung hình video tương lai, dẫn đến xu hướng dễ bỏ lỡ các chi tiết hình học nhỏ nhưng có tính quyết định như tín hiệu đèn giao thông hoặc biển báo xa.

Ngược lại, kiến trúc dạng JEPA chỉ thực hiện các phép dự đoán động lực học hoàn toàn trong không gian tiềm ẩn (latent space) trừu tượng và loại bỏ hoàn toàn bước giải mã ảnh thô. Sự thay đổi này giúp tối ưu hóa tài nguyên phần cứng đáng kể ở pha suy luận dự báo, bảo toàn các cấu trúc ngữ cảnh ngữ nghĩa cấp cao (high-level semantic context) và mang lại độ bền vững (robustness) vượt trội trước các tác nhân nhiễu bề mặt cảm biến

[22]. Các ứng dụng thực tế điển hình của hệ hình học này có thể kể đến như GAIA-1, MILE, Drive-WM. Đặc biệt, xu hướng này gần đây đã mở rộng sang không gian dữ liệu hình học 3D với kiến trúc AD-L-JEPA (2025), ứng dụng học tự giám sát trên dữ liệu Point Cloud từ LiDAR để dự báo biểu diễn BEV tiềm ẩn mà không cần tái tạo các vùng không gian bị che khuất [22, 14].

1.3 Nhận thức Đa phương thức và Hệ sinh thái Mô hình Nền tảng trong Đảm bảo Tính Bền vững (Robustness)

Trong triển khai thực tế, việc đối mặt với sự phân phối đuôi dài (long-tailed distribution) của các tình huống hiếm gặp và nguy cấp (safety-critical corner cases) khiến độ bền bỉ (Robustness) của hệ thống trở thành yếu tố sống còn hơn là chỉ số chính xác trung bình (mAP) trên các tập dữ liệu đóng [23]. Dữ liệu thực tế trong vận hành luôn bị nhiễu động bởi các yếu tố môi trường (thời tiết, ánh sáng), sự thừa thớt vật lý của đám mây điểm LiDAR, và các lỗi sai lệch không gian - thời gian khi hợp nhất dữ liệu từ nhiều nguồn cảm biến khác nhau.

Để giải quyết các thách thức nhận thức hình học phức tạp này, các hệ thống hiện đại ứng dụng chiến lược hội tụ đa phương thức (Multi-modal Fusion), kết hợp lợi thế về đặc tính ngữ nghĩa (semantic) của Camera và thông tin hình học tuyệt đối (geometrical) của LiDAR. Xu hướng chủ đạo hiện nay là đưa dữ liệu về không gian Bird's-Eye-View (BEV) thông qua các cơ chế Middle Fusion, hoặc xây dựng bản đồ lưới chiếm chỗ 3D (3D Occupancy Grids). Phương pháp này đóng vai trò then chốt trong việc nhận diện các vật thể không có hình dáng chuẩn (irregular objects) và thiết lập ranh giới an toàn giúp xe tránh va chạm.

Tuy nhiên, tiến trình công nghệ giai đoạn 2025–2026 chỉ ra rằng năng lực nhận thức hình học thuần túy là chưa đủ để bao phủ hết sự phức tạp và các biến số bất định của thế giới thực. Theo khảo sát hệ thống của Gao et al. (2026), sự trỗi dậy của hệ sinh thái Mô hình Nền tảng (Foundation Models) — bao gồm các mô hình Thị giác - Ngôn ngữ lớn (VLMs) và mô hình Khuếch tán (Diffusion Models) — đã mở rộng ranh giới của xe tự hành vượt ra khỏi các tác vụ nhận thức cấu trúc hộp bao (bounding box) truyền thống [23].

Các mô hình nền tảng này đóng vai trò chiến lược song trùng: một mặt chủ động sinh thành các kịch bản cực đoan giả lập (Scenario Generation) có độ bao phủ và tính chân thực cao để huấn luyện xe trước các rủi ro; mặt khác cung cấp khả năng lập luận logic cấp cao (high-level reasoning) và phân tích ngữ cảnh kịch bản (Scenario Analysis) trực tiếp bằng ngôn ngữ tự nhiên [23]. Sự giao thoa giữa nhận thức hình học đa cảm biến và năng lực tư duy trừu tượng của mô hình nền tảng chính là chìa khóa để phá vỡ giới hạn của các tình huống đuôi dài, nâng cao toàn diện tính bền vững thực tế cho hệ thống lái tự động.

2 Xác định Research Gap

2.1 Tích hợp Nhận thức Đa phương thức (Multimodal sensor)

Vấn đề: Việc đạt được sự tự chủ hoàn toàn chỉ thông qua hệ thống tầm nhìn đơn nhãn (monocular vision) đặt ra những giới hạn không thể vượt qua về cả mặt hình học không gian lẫn độ an toàn hệ thống [1]. Đặc biệt tại bối cảnh giao thông đặc thù hỗn loạn như ở Việt Nam, mật độ xe máy di chuyển dày đặc san sát nhau tạo ra hiện tượng che khuất (occlusion) cực kỳ nghiêm trọng. Khi đó, luồng hình ảnh quang học (RGB) thuần túy không thể cung cấp đủ thông tin để thiết lập nhận thức chiều sâu vật lý chính xác, dễ dẫn đến việc ước lượng sai khoảng cách hoặc bỏ sót các đối tượng trong không gian 3D.

- **Đánh đổi giữa tính trừu tượng và độ chính xác hình học 3D:** Drive-JEPA dự đoán các trạng thái tương lai hoàn toàn trong một không gian tiềm ẩn (latent space) trừu tượng mà không giải mã rõ ràng ngược lại hệ tọa độ hình học trực quan như Bird's-Eye-View (BEV) hay Occupancy Grid [1]. Do đó, mô hình buộc phải phụ thuộc hoàn toàn vào một planner head để học ngầm ánh xạ giữa biến đổi của vectơ tiềm ẩn và các tọa độ vật lý (waypoints) [1]. Khoảng trống lý thuyết ở đây là sự thiếu vắng các ràng buộc hình học 3D tất định và mô hình động học xe đạp (kinematic bicycle model) trong hàm mất mát, khiến mạng nơ-ron không sở hữu hiểu biết toán học nội tại về tính hợp lý vật lý — như giới hạn quán tính, ranh giới không thể đi qua, hoặc ràng buộc non-holonomic [2].
- **Điểm mù toàn cảnh 360 độ:** Drive-JEPA hiện vẫn phụ thuộc chủ yếu vào một camera phía trước để xây dựng biểu diễn tiềm ẩn cho môi trường lái xe. Đây là ưu điểm về tính đơn giản của dữ liệu đầu vào, nhưng cũng tạo ra hạn chế lớn về khả năng quan sát toàn cảnh. Trong các giao lộ đông đúc hoặc môi trường giao thông hỗn tạp như ở Việt Nam, hệ thống có thể bỏ sót các phương tiện xuất hiện từ phía sau hoặc các vùng điểm mù hai bên sườn. Ngoài ra, khi xảy ra che khuất dày đặc bởi xe máy hoặc vật cản, camera RGB đơn thường khó suy luận đầy đủ cấu trúc không gian xung quanh. Việc bổ sung dữ liệu Depth hoặc Point Cloud có thể giúp bù đắp các vùng mù này và cải thiện khả năng nhận biết ngữ cảnh 3D. Tuy nhiên, thách thức đặt ra là làm thế nào để tích hợp trực tiếp các đặc trưng không gian này vào latent representation của JEPA mà vẫn đảm bảo hiệu năng tính toán thời gian thực. Mặc dù Drive-JEPA đã cho thấy hiệu quả trong cả thiết lập perception-free và perception-based trên NAVSIM, khả năng tổng quát hóa sang các môi trường thực tế có occlusion mạnh và cảm biến không đồng nhất vẫn còn là một hướng nghiên cứu mở.
- **Sự vắng mặt của Cảm biến Chủ động (LiDAR và Radar 4D):** Các mô hình dựa hoàn toàn trên video thường gặp khó khăn trong việc ước lượng chiều sâu chính

xác, đặc biệt dưới điều kiện thời tiết xấu, ánh sáng yếu hoặc hiện tượng chói sáng. Vì vậy, cộng đồng xe tự hành đang chuyển dần sang các hệ thống multi-sensor fusion, kết hợp camera với LiDAR và Radar 4D để khai thác đồng thời thông tin hình ảnh, hình học không gian và vận tốc vật lý. Gần đây, AD-L-JEPA (Autonomous Driving LiDAR JEPA) đã mở rộng kiến trúc JEPA sang dữ liệu point cloud bằng cách dự đoán biểu diễn Bird's-Eye-View thay vì tái tạo trực tiếp các vùng bị che khuất, qua đó cải thiện hiệu quả phát hiện đối tượng 3D và giảm đáng kể chi phí bộ nhớ GPU. Tuy nhiên, Drive-JEPA và AD-L-JEPA hiện vẫn hoạt động như các hệ thống tách biệt theo từng modality. Một hướng nghiên cứu quan trọng trong tương lai là xây dựng kiến trúc “Multi-Modal Fusion JEPA”, nơi camera, LiDAR và Radar được học trong cùng một không gian latent thống nhất. Bên cạnh đó, khi số lượng cảm biến tăng lên, hệ thống cũng trở nên nhạy cảm hơn với các cuộc tấn công nhận thức chéo phương thức (cross-modal perception attacks), chẳng hạn như giả mạo dữ liệu đồng bộ giữa LiDAR và cảm biến hồng ngoại. Độ bền vững của latent representation JEPA trước các nhiễu đối kháng trên dữ liệu đa cảm biến hiện vẫn là một bài toán chưa được giải quyết triệt để. Hơn thế nữa, việc dung hợp trực tiếp các đặc trưng không gian 3D nào vào latent representation của JEPA mà không làm tăng đáng kể chi phí tính toán thời gian thực cũng là một điểm cần chú ý.

Bảng 1: Hạn chế của các phương thức cảm biến trong kiến trúc JEPA hiện hành

Phương thức Cảm biến	Lợi thế Khách quan	Điểm mù / Hạn chế Tương đối	Ứng dụng
Camera Đơn nhân (Front-view)	Cung cấp kết cấu ngữ nghĩa, nhận diện màu sắc, biển báo; chi phí thấp.	Không có thông tin 360 độ; ước lượng chiều sâu kém; dễ bị vô hiệu hóa bởi thời tiết và ánh sáng yếu.	Drive-JEPA [1]
Camera Đa góc nhìn (Multi-view)	Phủ sóng 360 độ, xử lý tốt các tình huống tại giao lộ phức tạp.	Bùng nổ khối lượng tính toán (FLOPs) trong các mô hình Transformer; khó đồng bộ dữ liệu thời gian thực.	Chưa được tích hợp trong bộ khung Drive-JEPA [1].
LiDAR	Cung cấp bản đồ chiếm chỗ (occupancy) 3D chính xác tuyệt đối; không phụ thuộc vào nguồn sáng.	Thiếu hụt thông tin kết cấu, màu sắc; hiệu năng dễ bị nhiễu do các hạt mưa hoặc sương mù lớn.	AD-L-JEPA [14]
Radar mmWave 4D (<i>không có dữ liệu</i>)	Khả năng xuyên thấu thời tiết; ước lượng trực tiếp vận tốc Doppler và cao độ đối tượng.	Độ phân giải không gian tương đối thấp; dễ sinh ra các điểm nhiễu ảo (ghost objects).	Chưa có nghiên cứu ứng dụng JEPA cụ thể [6].

2.2 Hạn chế trong Cơ chế Chứng cất Quỹ đạo Đa phương thức

Vấn đề: Khi đối mặt với một tình huống giao thông, thường có nhiều quỹ đạo di chuyển an toàn khác nhau (tính đa phương thức). Tuy nhiên, dữ liệu video huấn luyện thường chỉ cung cấp một quỹ đạo duy nhất của người lái xe, khiến mô hình dễ bị "sụp đổ phương thức" (modal collapse) — đưa ra quyết định sai lầm do lấy trung bình các quỹ đạo [1]. Để khắc phục, Drive-JEPA sử dụng trình mô phỏng để tạo ra thêm nhiều quỹ đạo ảo, sau đó huấn luyện mô hình học (chứng cất) từ tập hợp này [1]. Tuy nhiên, giải pháp này lại phát sinh những lỗ hổng chí mạng khi vận hành trong thực tế.

- **Nghịch lý chứng cất từ Mô phỏng sang Thực tế (Sim-to-Real Paradox):**

Trình mô phỏng thường hoạt động dựa trên các quy tắc (heuristics) cứng nhắc [1]. Ví dụ, khi gặp vật cản, một người lái xe chuyên nghiệp có thể lẩn nhẹ vạch kẻ đường để vượt qua một cách an toàn và trơn tru. Ngược lại, trình mô phỏng có thể đánh giá việc lẩn vạch là "rủi ro cao" và chỉ đề xuất phương án phanh gấp. Việc ép mô hình mạng nơ-ron học theo các quỹ đạo mô phỏng này vô tình làm thu hẹp sự linh hoạt của chuyên gia con người. Drive-JEPA hiện thiếu một cơ chế đánh giá độ tin

cây để phân định xem nên tin vào phản xạ của con người hay luật của máy móc khi xảy ra xung đột [1].

- **Sự dễ tổn thương của cơ chế nhận thức động lượng tĩnh:** Sau khi tạo ra tập hợp các đề xuất, Drive-JEPA sử dụng mô-đun lựa chọn quỹ đạo nhận thức động lượng (momentum-aware trajectory selection) để trừng phạt các bước chuyển tiếp có độ giật cao (high-jerk) nhằm duy trì tính êm ái xuyên khung hình [1]. Cơ chế này hoạt động như một hàm làm mịn thời gian thuần túy thay vì một công cụ đánh giá rủi ro chủ động [1]. Trong các kịch bản nguy cấp thiết yếu (ví dụ: chướng ngại vật bất ngờ xuất hiện), hành động tối ưu bắt buộc phải chấp nhận độ giật lớn, giảm tốc đột ngột hoặc bẻ lái gắt. Một hàm heuristic tĩnh có thể loại bỏ các thao tác sinh tử này chỉ để ưu tiên tính liên tục của khung hình, dẫn đến việc chậm trễ phản ứng hoặc chọn sai quỹ đạo [1, 8].
- **Lỗi hỏng xử lý tình huống bị che khuất (Occlusion Scenarios):** Khi không có bộ nhớ lấy đối tượng làm trung tâm (object-centric memory) hoặc tính năng theo dõi bền bỉ (persistent tracking) bên trong biểu diễn tiềm ẩn, chân trời dự đoán của mô hình sụp đổ ngay khi bằng chứng thị giác biến mất sau vật cản [8]. Drive-JEPA xử lý thông tin dựa trên quan sát không gian tiềm ẩn tại thời điểm hiện tại. Khi một tác nhân giao thông (ví dụ: người đi bộ) di chuyển khuất sau một chiếc xe tải, bằng chứng thị giác biến mất và chân trời dự đoán của Drive-JEPA có nguy cơ sụp đổ [8]. Khác với các hệ thống như PerlAD — vốn tách biệt luồng xử lý và sử dụng học tăng cường (RL) để chủ động giảm tốc khi gặp vùng che khuất — Drive-JEPA thiếu một bộ nhớ theo dõi đối tượng bền bỉ (persistent tracking) để duy trì nhận thức về sự tồn tại của vật thể khi chúng không còn trong tầm nhìn [8, 1].

Bảng 2: Phân tích lỗi hỏng trong mô-đun lựa chọn và chứng cất quỹ đạo của Drive-JEPA

Thành phần	Mục đích Ban đầu	Khoảng trống Nghiên cứu	Hệ lụy An toàn Thực tế
Chứng cất Quỹ đạo từ Mô phỏng	Tránh sụp đổ phương thức bằng cách cung cấp nhiều phương án lái xe ảo [1].	Kế thừa sự cứng nhắc của mô phỏng; thiếu cơ chế giải quyết xung đột với dữ liệu của con người.	Từ chối các pha xử lý linh hoạt của con người, mặc định chọn cách giải quyết bảo thủ, cứng nhắc.
Lựa chọn Quỹ đạo Nhận thức Động lượng	Đảm bảo xe chạy êm ái, không bị giật cục [1].	Dùng hàm tính toán tĩnh, không phân biệt được giữa lái xe bình thường và tình huống khẩn cấp.	Gạt bỏ các thao tác bẻ lái/phanh gấp cứu mạng, dẫn đến va chạm khi có vật cản lao ra đột ngột.
Xử lý vùng Che khuất (Occlusion)	Dự đoán diễn biến tương lai trong không gian tiềm ẩn.	Thiếu bộ nhớ duy trì đối tượng; dự đoán bị đứt gãy khi vật thể bị che khuất [8].	Không có phản xạ phòng thủ (giảm tốc) khi người đi bộ bất ngờ bước ra từ điểm mù.

2.3 Mô hình hóa Động lực học Tương tác Đa tác nhân và Thách thức Định chuẩn trong Môi trường Phi cấu trúc

Một luận điểm trung tâm đặt ra đối với các hệ thống lái tự động hiện nay là chúng vẫn còn nhiều hạn chế trong việc mô hình hóa các tương tác động lực học thể thân trong môi trường giao thông phi cấu trúc ngoài đời thực. Sự phụ thuộc quá mức vào điểm số thực nghiệm cao trên các bảng xếp hạng tổng hợp hiện nay vô hình trung đang che giấu sự đứt gãy lớn giữa môi trường kiểm thử lý thuyết và năng lực tương tác nhân quả khép kín thực tế [1, 9].

- **Sự Lệch pha giữa Định kiến Giao thông Có cấu trúc và Thực tế Hỗn hợp Phi cấu trúc:** Các bộ dữ liệu và hệ thống tiêu chuẩn (chủ yếu từ Bắc Mỹ và Châu Âu) thường được thiết lập dựa trên các định kiến giao thông có tính cấu trúc cao, nơi phương tiện tuân thủ nghiêm ngặt làn đường và hệ thống tín hiệu. Ngược lại, môi trường giao thông hỗn hợp tại Việt Nam sở hữu mức độ entropy tương tác (interaction entropy) đặc biệt lớn. Mật độ xe máy dày đặc, sự thương lượng không chính thức (informal negotiation), cơ chế chia sẻ làn đường động và các hành vi phản ứng khiến các mô hình hiện tại khó có thể nắm bắt đầy đủ (insufficiently capture) động lực học phức tạp này [2].
- **Hạn chế Vòng lặp Giả khép kín (Pseudo Closed-Loop) của Hệ thống Đánh giá:** Sự thiếu hụt trong mô hình hóa tương tác thể hiện rõ qua các công cụ đánh giá. Điểm số vượt trội của Drive-JEPA đạt được phần lớn trên bộ kiểm chuẩn NAVSIM [1]. Mặc dù nền tảng này có hỗ trợ các tác nhân phản ứng, quy trình đánh giá thực chất vẫn duy trì tính chất “giả khép kín” (pseudo closed-loop) [9]. Trong đó, chiếc xe chủ (ego-vehicle) vẫn phải chốt (commit) một kế hoạch quỹ đạo cố định cho toàn bộ chân trời mô phỏng 4 giây. Việc này khiến hệ thống chỉ được tối ưu hóa cho khả năng bám theo quỹ đạo (trajectory following) thay vì thực sự tham gia vào các quá trình đàm phán tương tác (interactive negotiation) thực thụ tại các nút giao hỗn loạn [9, 19].
- **Sự Sai lệch giữa Tiêu chí Định chuẩn (Metric Misalignment) và Trí tuệ Tương tác:** Hệ quả trực tiếp của việc đánh giá giả khép kín là sự sai lệch sâu sắc trong các thước đo định chuẩn. Các hệ thống như PDM-Score hay CARLA Leaderboard thiên vị ngầm các định kiến lái xe có cấu trúc thông qua việc phạt nặng các vi phạm như lấn làn hoặc không giữ khoảng cách theo luật định. Tuy nhiên, trong thực tế giao thông hỗn hợp, các hành vi “linh hoạt nhưng an toàn” — chẳng hạn như chủ động lách qua một khoảng trống nhỏ ở vận tốc thấp — lại là chiến lược thiết yếu. Do đó, các bộ định chuẩn hiện tại đang tưởng thưởng cho sự tuân thủ quỹ đạo hình học nhiều hơn là khả năng trí tuệ tương tác thực tế.

- **Sự Thiếu hụt Kịch bản Đuôi dài và Miền Thiết kế Hoạt động Cục bộ (ODD Deficiency):** Thách thức định chuẩn này càng bộc lộ rõ khi các bộ benchmark hiện hành chưa đại diện đầy đủ các kịch bản phân phối đuôi dài (long-tailed distribution) mang tính cục bộ. Các tình huống tới hạn như: dòng người đi xe máy dày đặc tạt đầu, xe nâng (forklifts) di chuyển ngẫu nhiên trong Khu công nghiệp (KCN), hoặc các pha thương lượng bị che khuất tầm nhìn (occluded negotiation) hầu như vắng bóng. Việc thiếu vắng một hệ thống kiểm thử tương thích với Miền thiết kế hoạt động (ODD) hẹp như KCN hay giao thông hỗn hợp kiểu Việt Nam là một rào cản lớn trong việc đánh giá mức độ tin cậy.
- **Tiến trình hướng tới Mô hình Tương tác Hành động Thế giới (WAIM):** Về mặt kiến trúc, quy trình lập kế hoạch hạ lưu của Drive-JEPA chủ yếu mang tính chất một chiều (largely one-directional): trích xuất trạng thái tiềm ẩn và giải mã thành các đề xuất quỹ đạo waypoint [1]. Ngược lại, các nghiên cứu tiên tiến về Mô hình Tương tác Hành động Thế giới (WAIM) như DAWN chỉ ra rằng trạng thái thế giới và hành động của phương tiện cần đồng tiến hóa thông qua một vòng lặp “tưởng tượng đệ quy” (recursive imagination) ngay trong quá trình suy luận [4]. Việc thiếu các cuộc diễn tập tinh thần (mental rollouts) để liên tục đánh giá phản ứng ngược từ môi trường khiến bộ dự đoán của Drive-JEPA gặp khó khăn khi phải giải quyết các tương tác nhân quả khép kín [1, 4].
- **Thách thức trong Dự đoán Tương lai Đa phương thức (Multi-Modal Futures):** Cuối cùng, sự đứt gãy về vòng lặp tương tác trực tiếp làm giảm năng lực dự báo các tương lai đa phương thức ngẫu nhiên (stochastic futures). Mô hình hiện tại vẫn gặp khó khăn trong việc mô hình hóa tính bất định của tương tác. Trong môi trường hỗn hợp, nơi nhiều kịch bản phản ứng hợp lý có thể xảy ra cùng lúc, việc thiếu khả năng sinh thành các tương lai đa phương thức khiến hệ thống dễ bị trung bình hóa các quỹ đạo, từ đó làm giảm độ linh hoạt khi đối phó với giao thông phi cấu trúc.

2.4 Hiệu năng Tính toán trên Thiết bị Nhúng (Edge Deployment Computing)

Vấn đề: Các mô hình Transformer-based như JEPA yêu cầu tài nguyên rất lớn. Trong khi đó, các thiết bị tự hành thực tế (xe tự hành quy mô nhỏ, robot bốn chân) thường chỉ được trang bị các máy tính nhúng với giới hạn khắt khe về năng lượng, tản nhiệt và bộ nhớ. Một hệ thống tự hành thời gian thực luôn hoạt động dưới những ràng buộc khắt khe về độ trễ quyết định (decision latency không được vượt quá 50–100ms). Việc đưa một kiến trúc dựa trên nền tảng mạng xương sống Vision Transformer nặng nề lên các máy tính nhúng biên đặt ra những thách thức vật lý cực hạn.

- **Chi phí huấn luyện khổng lồ:** Drive-JEPA phụ thuộc vào các mạng xương sống quy mô lớn (như ViT/L) để đạt được sức mạnh biểu diễn tiềm ẩn [1]. Tuy nhiên, độ phức tạp tính toán của cơ chế tự chú ý (self-attention) tăng theo cấp số nhân so với độ dài chuỗi đầu vào — bao gồm số lượng khung hình video và các bản vá không gian — dễ gây quá tải nghiêm trọng cho các Hệ thống trên Chip (SoCs) chuẩn ô tô hiện tại [12]. Khác với các kiến trúc tối ưu hóa phần cứng thông minh bằng cách tái sử dụng bộ đệm chia sẻ (như cơ chế Shared-Prefix KV cache của ReflectDrive-2), Drive-JEPA hiện đang hoàn toàn thiếu vắng các giải pháp làm thưa thớt sự chú ý không gian–thời gian hoặc cắt tỉa token động (dynamic token pruning) để đáp ứng ràng buộc thời gian thực [10, 12].
- **Độ trễ suy luận (Inference Latency):** Chưa có các đánh giá cụ thể về thời gian trễ (mili-giây/khung hình) của Drive-JEPA. Kích thước mô hình hiện tại khiến việc suy luận theo thời gian thực (real-time inference) để phục vụ vòng lặp điều khiển trên phần cứng nhúng là một thách thức lớn.

Tài liệu tham khảo

- [1] L. Wang et al., “Drive-JEPA: Video JEPA Meets Multimodal Trajectory Distillation for End-to-End Driving,” *arXiv preprint* arXiv:2601.22032v1, Jan. 2026.
- [2] “HanoiWorld: A Joint Embedding Predictive Architecture Based World Model for Autonomous Vehicle Controller,” *arXiv preprint* arXiv:2601.01577v1, Jan. 2026.
- [3] Y. LeCun, “A Path Towards Autonomous Machine Intelligence Version 0.9.2,” *OpenReview*, Jun. 2022. [Online]. Available: <https://openreview.net/pdf?id=BZ5a1r-kVsf>
- [4] “The DAWN of World-Action Interactive Models,” *arXiv preprint* arXiv:2605.11550v1, May 2026.
- [5] “Self-Supervised Representation Learning with Joint Embedding Predictive Architecture for Automotive LiDAR Object Detection,” *arXiv preprint* arXiv:2501.04969, Jan. 2025.
- [6] “4D mmWave Radar for Autonomous Driving Perception: A Comprehensive Survey,” *ResearchGate*, Mar. 2024.
- [7] “Zero-Shot Cross-City Generalization in End-to-End Autonomous Driving: Self-Supervised versus Supervised Representations,” *arXiv preprint* arXiv:2603.11417v1, Mar. 2026.
- [8] “Pseudo-simulation-based Reinforcement Learning for Occlusion Scenarios in Autonomous Driving,” *arXiv preprint*, 2026.
- [9] D. Dauner et al., “NAVSIM: Data-Driven Non-Reactive Autonomous Vehicle Simulation and Benchmarking,” in *Proc. NeurIPS Datasets and Benchmarks Track*, 2024.
- [10] “ReflectDrive-2: Reinforcement-Learning-Aligned Self-Editing for Discrete Diffusion Driving,” *alphaXiv preprint* arXiv:2605.04647, May 2026.
- [11] “Awesome-LLM-for-Autonomous-Driving-Resources,” GitHub Repository, thinklab-sjtu, 2026. [Online]. Available: <https://github.com/thinklab-sjtu/awesome-llm4ad>
- [12] “DriveTransformer: Unified Transformer for Scalable End-to-End Autonomous Driving,” *Technical Report / Semantic Scholar*, 2025.

- [13] “Tutorial on Joint Embedding Predictive Architectures (JEPA): Foundations, Applications, and Future Directions,” *TechRxiv*, 2025. doi: 10.36227/techrxiv.176469421.19270944.
- [14] “AD-L-JEPA: Self-Supervised Spatial World Models with Joint Embedding Predictive Architecture for Autonomous Driving with LiDAR Data,” *ResearchGate*, 2025. [Online]. Available: <https://www.researchgate.net/publication/387872946>
- [15] “CoVLA: Comprehensive Vision-Language-Action Dataset for Autonomous Driving,” *ResearchGate*, 2025.
- [16] “The Role of World Models in Shaping Autonomous Driving: A Comprehensive Survey,” *arXiv preprint* arXiv:2502.10498v2, 2025.
- [17] “Driving Into the Future: Multiview Visual Forecasting and Planning with World Model for Autonomous Driving,” *ResearchGate*, 2024.
- [18] “LongTail Driving Scenarios with Reasoning Traces: The KITScenes LongTail Dataset,” *arXiv preprint* arXiv:2603.23607v2, 2026.
- [19] Z. Chen, T. Hui, X. Zhu, and D. Su, “Traffic Anomaly Detection through Generative Modeling of Multi-Agent Interactions in Traffic Flow,” pp. 2463–2465, May 2025. doi: 10.65109/kjnd2746.
- [20] “CADRE: A Cascade Deep Reinforcement Learning Framework for Vision-based Autonomous Urban Driving,” *arXiv preprint* arXiv:2202.08557, Feb. 2022.
- [21] J. Zhao *et al.*, “A Survey of Autonomous Driving from a Deep Learning Perspective,” *arXiv preprint*, 2025.
- [22] T. Feng, W. Wang, and Y. Yang, “A Survey of World Models for Autonomous Driving,” *arXiv preprint* arXiv:2501.11260, 2025.
- [23] Y. Gao *et al.*, “Foundation Models in Autonomous Driving: A Survey on Scenario Generation and Scenario Analysis,” *IEEE Open Journal of Intelligent Transportation Systems*, 2026. doi: 10.1109/OJITS.2026.3660686.