

BÁO CÁO NGHIÊN CỨU

Ba khung toán học độc lập

Anytime-Valid Control – Counterfactual Safety Bound – Causal Reinforcement Learning

Mục lục

1	Anytime-Valid Control	3
1.1	Động lực và bài toán đặt ra	3
1.2	Hạn chế của các phương pháp thống kê truyền thống	3
1.3	Anytime-Valid Control: định nghĩa và trực giác	4
1.4	Mô hình toán học và các ký hiệu cơ bản	4
1.5	Các công thức chính	5
1.6	Các định lý nền tảng	5
1.6.1	Bất đẳng thức Ville	5
1.6.2	Định lý tùy ý dừng	6
1.6.3	Tính chấp nhận được của các quy trình e-process	6
1.6.4	Chuyển đổi từ kiểm định tĩnh sang kiểm định tuần tự	6
1.7	Trực giác của các công thức	6
1.8	Giả định và điều kiện áp dụng	7
1.9	Hạn chế	7
1.10	Các nghiên cứu tiêu biểu	7
1.11	Các nghiên cứu gần đây	10
1.12	Hạn chế và Các thách thức mở	12
2	Counterfactual Safety Bound	13
2.1	Động lực	13
2.2	Counterfactual là gì?	13
2.3	Mô hình Nhân quả Cấu trúc (SCM)	14
2.4	Kết quả Tiềm năng	15
2.5	Do-calculus	15
2.6	Biên an toàn (Safety Bound)	15
2.7	Các công thức nền tảng	16
2.8	Các định lý cơ bản	17
2.9	Các giả định cốt lõi	17
2.10	Điều kiện áp dụng	18
2.11	Hạn chế	18
2.12	Các nghiên cứu kinh điển	19
2.13	Các nghiên cứu đương đại	19
2.13.1	Towards Safe Policy Learning under Partial Identifiability: A Causal Approach	20
2.13.2	Robust Counterfactual Inference in Markov Decision Processes	21
2.13.3	Partial Counterfactual Identification of Continuous Outcomes with a Curvature Sensitivity Model	21
2.14	Các thách thức mở	22

3 Causal Reinforcement Learning	23
3.1 Động lực và Trực giác	23
3.2 Ba lĩnh vực	23
3.3 Nền tảng toán học	23
3.4 Causal MDP	24
3.5 Intervention và Counterfactual trong RL	24
3.6 Causal Decision-Making	25
3.7 Khung công thức thống nhất	25
3.8 Định lý và điều kiện nhận dạng	26
3.9 Các giả định	26
3.10 Điều kiện áp dụng	26
3.11 Hạn chế lý thuyết	27
3.12 Ví dụ minh họa	27
3.13 Các thách thức mở	27
Tài liệu tham khảo	29

1 Anytime-Valid Control

1.1 Động lực và bài toán đặt ra

Các hệ thống khoa học dữ liệu và hệ thống tự trị hiện đại ngày càng phải xử lý dữ liệu theo dạng luồng (*streaming data*). Dữ liệu không được thu thập đầy đủ trước khi phân tích mà liên tục xuất hiện trong quá trình hệ thống hoạt động. Vì vậy, nhiều quyết định cũng cần được đưa ra theo thời gian thực, chẳng hạn như có nên dừng một quá trình, cập nhật mô hình, phát cảnh báo hay chuyển sang một chế độ an toàn hơn.

Điều này tạo ra một hạn chế đối với các phương pháp thống kê truyền thống. Phần lớn các phương pháp suy diễn thống kê được xây dựng với một kích thước mẫu hoặc một thời điểm phân tích cố định. Trong khi đó, các hệ thống trực tuyến thường không biết trước khi nào sẽ có đủ thông tin để đưa ra quyết định. Thời điểm dừng có thể phụ thuộc trực tiếp vào những dữ liệu đã quan sát được.

Một bài toán quan trọng được đặt ra là: làm thế nào để một hệ thống có thể liên tục quan sát dữ liệu, đánh giá bằng chứng thống kê và dừng tại một thời điểm bất kỳ, nhưng vẫn duy trì được bảo đảm về xác suất mắc sai lầm?

Bài toán này xuất hiện trong nhiều bối cảnh như hệ thống tự động hóa, học tăng cường, kiểm định A/B, giám sát mô hình học máy và phát hiện thay đổi trong phân phối dữ liệu. Về bản chất, đây là điểm giao giữa thống kê tuần tự (*sequential statistics*) và lý thuyết điều khiển (*control theory*). Hệ thống không chỉ cần đưa ra quyết định chính xác tại một thời điểm cố định mà còn phải duy trì tính hợp lệ trong suốt quá trình vận hành.

1.2 Hạn chế của các phương pháp thống kê truyền thống

Các phương pháp phổ biến như kiểm định giả thuyết dựa trên p -value và khoảng tin cậy (*confidence interval*) thường được xây dựng cho bài toán có kích thước mẫu cố định. Trong thiết lập này, số lượng mẫu N được xác định trước, sau đó kết luận được đưa ra tại một thời điểm đã định.

Tuy nhiên, trong thực tế, việc liên tục kiểm tra dữ liệu là một nhu cầu tự nhiên. Một nhà nghiên cứu có thể muốn xem kết quả sau mỗi nhóm mẫu mới. Một hệ thống giám sát có thể kiểm tra mô hình sau mỗi lần cập nhật. Một bộ điều khiển có thể cần đánh giá trạng thái sau từng bước thời gian.

Nếu sử dụng trực tiếp các kiểm định cố định trong những tình huống này và dừng ngay khi kết quả đạt ngưỡng ý nghĩa thống kê, bảo đảm xác suất ban đầu có thể không còn đúng. Cách tiếp cận này thường được gọi là *optional stopping* hoặc *peeking*. Việc lặp lại kiểm định nhiều lần làm tăng khả năng quan sát được một kết quả có vẻ có ý nghĩa chỉ do ngẫu nhiên, dẫn đến hiện tượng lạm phát sai lầm loại I (*Type-I error inflation*).

Vấn đề này cũng xuất hiện trong các hệ thống học trực tuyến. Chẳng hạn, trong cây quyết định dòng dữ liệu, việc liên tục kiểm tra các điều kiện để thực hiện phép chia nhánh có thể khiến các ranh giới thống kê cố định bị sử dụng nhiều lần. Nếu không có cơ chế điều chỉnh phù hợp, xác suất đưa ra một quyết định chia nhánh sai có thể tăng theo số lần kiểm tra.

Tương tự, các phương pháp *Conformal Prediction* truyền thống thường cung cấp bảo đảm rủi ro dựa trên một tập hiệu chuẩn cố định. Khi dữ liệu tiếp tục được đưa vào hệ thống trong thời gian dài, việc duy trì cùng một mức bảo đảm tại mọi thời điểm không còn là điều tự động được đảm bảo.

1.3 Anytime-Valid Control: định nghĩa và trực giác

Anytime-Valid Control (AVC) có thể được hiểu là một khuôn khổ cho phép xây dựng các quy trình thống kê và điều khiển sao cho các bảo đảm về sai số hoặc rủi ro vẫn được duy trì trong quá trình quan sát liên tục. Điểm quan trọng là thời điểm dừng không cần phải được xác định trước mà có thể phụ thuộc vào dữ liệu.

Một cơ chế được gọi là *anytime-valid* đối với mức rủi ro $\alpha \in (0, 1)$ nếu bảo đảm thống kê vẫn đúng tại mọi thời điểm dừng hợp lệ, kể cả khi thời điểm đó được lựa chọn dựa trên những quan sát trước đó.

Trực giác của AVC có thể được mô tả thông qua ý tưởng “kiểm định bằng cá cược”. Giả sử $\mathcal{H}_0$ đại diện cho trạng thái bình thường hoặc trạng thái an toàn của hệ thống. Một chiến lược kiểm định bắt đầu với một lượng tài sản ban đầu, thường được chuẩn hóa bằng 1. Sau mỗi quan sát, chiến lược này cập nhật tài sản dựa trên mức độ phù hợp của dữ liệu với $\mathcal{H}_0$.

Nếu $\mathcal{H}_0$ thực sự đúng, tài sản kỳ vọng của chiến lược không được tăng lên một cách có hệ thống. Ngược lại, nếu dữ liệu liên tục cho thấy bằng chứng chống lại $\mathcal{H}_0$, tài sản có thể tăng dần theo thời gian.

Quá trình tích lũy tài sản này được mô hình hóa bằng một siêu martingale không âm. Theo bất đẳng thức Ville, xác suất để quá trình vượt qua một ngưỡng lớn tại bất kỳ thời điểm nào vẫn có thể được kiểm soát. Vì vậy, hệ thống có thể liên tục quan sát quá trình và kích hoạt quyết định khi tài sản đạt ngưỡng mà không cần xác định trước thời điểm kiểm tra cuối cùng.

1.4 Mô hình toán học và các ký hiệu cơ bản

Mô hình của AVC được xây dựng trên một không gian xác suất $(\Omega, \mathcal{F}, \mathbb{P})$ với $\mathbb{F} = (\mathcal{F}_t)_{t \geq 0}$.

Trong đó, $\mathcal{F}_t$ biểu diễn toàn bộ thông tin mà hệ thống đã quan sát được cho đến thời điểm t . Gọi $\mathcal{P}$ là tập các phân phối xác suất có thể sinh ra luồng dữ liệu. Tập $\mathcal{H}_0 \subseteq \mathcal{P}$ đại diện cho các phân phối tương ứng với trạng thái bình thường hoặc trạng thái an toàn cần được kiểm soát.

Một quá trình ngẫu nhiên không âm

$$M = (M_t)_{t \geq 0}$$

được gọi là một quá trình kiểm định hợp lệ nếu nó thích nghi với bộ lọc $\mathbb{F}$ và thỏa mãn điều kiện siêu martingale dưới mọi phân phối $\mathbb{P} \in \mathcal{H}_0$:

$$\mathbb{E}^{\mathbb{P}}[M_t | \mathcal{F}_{t-1}] \leq M_{t-1} \quad \text{a.s.}$$

Thông thường, quá trình được khởi tạo với $M_0 \leq 1$.

Các ký hiệu chính được sử dụng trong mô hình gồm:

$(\Omega, \mathcal{F}, \mathbb{F}, \mathbb{P})$ Không gian xác suất cùng với bộ lọc và phân phối xác suất.

$\mathcal{F}_t$ Thông tin quan sát được tại thời điểm t .

$\mathcal{H}_0, \mathcal{H}_1$ Tập các phân phối đại diện cho trạng thái bình thường và trạng thái thay thế hoặc bất thường.

$\alpha \in (0, 1)$ Mức rủi ro hoặc mức ý nghĩa được cho phép.

E_t Giá trị-e tại thời điểm t , biểu diễn bằng chứng thu được từ quan sát mới.

M_t Quá trình tài sản hoặc quá trình tích lũy bằng chứng.

τ Thời điểm dừng, có thể phụ thuộc vào dữ liệu.

C_t Chuỗi tin cậy (*confidence sequence*) tại thời điểm t .

θ Tham số cần ước lượng hoặc kiểm soát.

λ_t, B_t Các tham số điều khiển hoặc hệ số cược được lựa chọn dựa trên thông tin quá khứ.

1.5 Các công thức chính

Tại mỗi thời điểm t , một giá trị- e E_t được xây dựng sao cho

$$E_t \geq 0$$

và

$$\mathbb{E}_{\mathbb{P}}[E_t \mid \mathcal{F}_{t-1}] \leq 1, \quad \forall \mathbb{P} \in \mathcal{H}_0.$$

Từ các giá trị- e này, quá trình tích lũy bằng chứng được xây dựng theo dạng tích:

$$M_t = M_{t-1} E_t = \prod_{i=1}^t E_i.$$

Một quy tắc dừng đơn giản có thể được viết như sau:

$$\tau = \inf \left\{ t \geq 1 : M_t \geq \frac{1}{\alpha} \right\}.$$

Khi quá trình vượt qua ngưỡng $1/\alpha$, hệ thống có thể đưa ra quyết định chống lại $\mathcal{H}_0$. Theo bất đẳng thức Ville, xác suất quá trình vượt qua ngưỡng này tại bất kỳ thời điểm nào vẫn bị chặn bởi α .

Đối với chuỗi tin cậy, một bảo đảm anytime-valid có dạng:

$$\mathbb{P}_{\theta}(\exists t \geq 1 : \theta \notin C_t) \leq \alpha.$$

Khác với khoảng tin cậy thông thường, điều kiện này kiểm soát đồng thời toàn bộ các thời điểm quan sát thay vì chỉ một kích thước mẫu cố định.

Trong các bài toán có yêu cầu phát hiện sớm, việc lựa chọn chiến lược cập nhật cũng có thể được tối ưu theo thời gian. Một cách tiếp cận là mô hình hóa quá trình này dưới dạng bài toán điều khiển tối ưu:

$$v(z) = \max_{a \in \mathcal{A}} \mathbb{E}_{\pi_1} [R(1) + v(z \cdot E(a, X))],$$

trong đó z là tài sản hiện tại và a là chiến lược hành động hoặc chiến lược cược.

1.6 Các định lý nền tảng

1.6.1 Bất đẳng thức Ville

Đối với một siêu martingale không âm $(M_t)_{t \geq 0}$ và một hằng số $c > 0$, bất đẳng thức Ville cho:

$$\mathbb{P}(\sup_{t \geq 0} M_t \geq c) \leq \frac{\mathbb{E}[M_0]}{c}.$$

Nếu $M_0 \leq 1$ và chọn

$$c = \frac{1}{\alpha},$$

thì ta thu được:

$$\mathbb{P} \left(\sup_{t \geq 0} M_t \geq \frac{1}{\alpha} \right) \leq \alpha.$$

Đây là cơ sở quan trọng của tính hợp lệ mọi thời điểm. Hệ thống có thể tiếp tục quan sát dữ liệu mà không cần xác định trước số lần kiểm tra.

1.6.2 Định lý tùy ý dừng

Đối với một số lớp siêu martingale và thời điểm dừng phù hợp, định lý tùy ý dừng cho thấy kỳ vọng tại thời điểm dừng không vượt quá kỳ vọng ban đầu: $\mathbb{E}[M_\tau] \leq \mathbb{E}[M_0]$.

Kết quả này giải thích vì sao việc lựa chọn thời điểm dừng dựa trên dữ liệu không tự động tạo ra một lợi thế thống kê dưới giả thuyết rỗng.

1.6.3 Tính chấp nhận được của các quy trình e-process

Một hướng nghiên cứu quan trọng trong thống kê an toàn là nghiên cứu các quy trình kiểm định có tính *admissible*. Ý tưởng chính là so sánh các quy trình hợp lệ với nhau để xác định liệu một quy trình có bị một quy trình khác vượt trội hoàn toàn hay không.

Các kết quả trong hướng này cho thấy các siêu martingale không âm và e-process đóng vai trò trung tâm trong việc mô tả những quy trình suy diễn tuần tự hợp lệ và có tính cạnh tranh.

1.6.4 Chuyển đổi từ kiểm định tĩnh sang kiểm định tuần tự

Một hướng tiếp cận gần đây nghiên cứu khả năng chuyển một kiểm định tĩnh thành một kiểm định tuần tự bằng cách lấy kỳ vọng có điều kiện: $\mathbb{E}_{\mathbb{P}}[\phi_N | \mathcal{F}_n]$.

Quá trình thu được có thể liên hệ với Doob martingale. Kết quả này cho thấy việc xây dựng một kiểm định hợp lệ mọi thời điểm không nhất thiết luôn yêu cầu thiết kế một phương pháp hoàn toàn mới từ đầu.

1.7 Trực giác của các công thức

Công thức

$$M_t = \prod_{i=1}^t E_i$$

thể hiện cách bằng chứng được tích lũy qua thời gian. Nếu các quan sát liên tục ủng hộ giả thuyết thay thế, các giá trị- e có thể lớn hơn 1 và làm tăng M_t . Ngược lại, nếu dữ liệu phù hợp với $\mathcal{H}_0$, quá trình không có cơ chế tăng trưởng có hệ thống.

Việc sử dụng phép nhân khiến các bằng chứng nhất quán được tích lũy theo thời gian. Tuy nhiên, tốc độ tăng trưởng thực tế phụ thuộc vào cách xây dựng các giá trị- e và đặc điểm của dữ liệu.

Đối với bất đẳng thức Ville,

$$\mathbb{P} \left(\sup_t M_t \geq \frac{1}{\alpha} \right) \leq \alpha,$$

ý nghĩa quan trọng nhất là hệ thống có thể kiểm tra quá trình nhiều lần mà không cần cộng thêm một mức phạt cho mỗi lần quan sát như trong các kiểm định cố định truyền thống.

Chuỗi tin cậy cũng có thể được hình dung như một vùng an toàn thay đổi theo thời gian. Tham số thực θ được kỳ vọng nằm trong vùng C_t trong toàn bộ quá trình, với xác suất vi phạm được kiểm soát bởi α .

1.8 Giả định và điều kiện áp dụng

Một giả định quan trọng là chiến lược cập nhật tại thời điểm t chỉ được sử dụng thông tin có sẵn trước khi quan sát X_t . Nói cách khác, các chiến lược cược phải có tính dự đoán được (*predictable*) đối với bộ lọc $\mathcal{F}_{t-1}$. Nếu sử dụng chính quan sát hiện tại để điều chỉnh chiến lược theo cách phá vỡ điều kiện kỳ vọng, tính chất siêu martingale có thể không còn đúng.

Khi nhiều quy trình được chạy song song, việc xử lý thông tin giữa các luồng cũng cần được kiểm soát. Các phụ thuộc chưa được mô hình hóa hoặc hiện tượng rò rỉ thông tin giữa các bộ lọc có thể ảnh hưởng đến bảo đảm thống kê.

Ngoài ra, đặc điểm phân phối của dữ liệu cũng đóng vai trò quan trọng. Nhiều phương pháp xây dựng martingale mũ yêu cầu dữ liệu bị chặn hoặc có các điều kiện về đuôi phân phối, chẳng hạn như tính chất Sub-Gaussian. Với dữ liệu có đuôi nặng, cần sử dụng các kỹ thuật bền vững hơn để kiểm soát ảnh hưởng của các quan sát cực đoan.

AVC đặc biệt phù hợp với các hệ thống có luồng dữ liệu tuần tự, thời điểm kết thúc không biết trước hoặc có nhu cầu giám sát liên tục. Các ví dụ bao gồm dữ liệu cảm biến của robot, hệ thống giao dịch, giám sát mô hình học máy và các thử nghiệm cần được phân tích trong quá trình đang diễn ra.

1.9 Hạn chế

Mặc dù cung cấp bảo đảm mạnh hơn cho việc giám sát liên tục, Anytime-Valid Control vẫn tồn tại một số đánh đổi.

Thứ nhất, tính hợp lệ tại mọi thời điểm có thể làm giảm sức mạnh thống kê tại một thời điểm cụ thể so với một kiểm định được thiết kế riêng cho kích thước mẫu cố định. Các chuỗi tin cậy cũng có thể rộng hơn so với khoảng tin cậy thông thường tại cùng một thời điểm.

Thứ hai, việc tối ưu hóa e-process trong các bài toán có giả thuyết rỗng phức tạp có thể đòi hỏi nhiều tính toán. Khi không gian tham số lớn hoặc có nhiều tham số nhiều, việc tìm chiến lược cược hiệu quả có thể trở thành một bài toán tối ưu hóa khó.

Cuối cùng, trong môi trường có sự thay đổi phân phối nhanh, việc duy trì đồng thời tính hợp lệ và độ nhạy phát hiện là một thách thức. Một phương pháp quá bảo thủ có thể phản ứng chậm với thay đổi, trong khi một phương pháp thích nghi quá nhanh có thể làm suy yếu bảo đảm thống kê.

1.10 Các nghiên cứu tiêu biểu

Ba công trình dưới đây có thể được xem là những nền tảng quan trọng của hướng nghiên cứu Safe Anytime-Valid Inference (SAVI). Mỗi công trình tập trung vào một khía cạnh khác nhau: xây dựng đơn vị đo bằng chứng, kiểm soát tính hợp lệ theo thời gian và hệ thống hóa các kết quả trong một khung lý thuyết thống nhất. Sự kết hợp của các hướng tiếp cận này tạo cơ sở cho việc phát triển các phương pháp suy luận thống kê có thể cập nhật liên tục mà vẫn duy trì các bảo đảm xác suất.

1. “Safe Testing” (Grünwald, de Heide, & Koolen, 2024)

Câu chuyện bắt đầu từ một vấn đề rất đời thường trong khoa học thực nghiệm: nhà nghiên

cứ chạy thử nghiệm, nhìn p-value, thấy nó gần 0.05, và — hoàn toàn "tự nhiên" về mặt tâm lý — quyết định thu thập thêm dữ liệu để "chắc ăn". Vấn đề là hành động này, dù trông vô hại, lại phá vỡ toàn bộ nền tảng của kiểm định giả thuyết cổ điển. p-value được xây dựng cho một cỡ mẫu *cố định từ trước*; khi cỡ mẫu phụ thuộc vào chính dữ liệu quan sát được (optional continuation / optional stopping), xác suất bắt gặp p-value nhỏ dưới H_0 không còn bị chặn ở α nữa — nó có thể tiệm cận 1 nếu người ta kiên nhẫn đủ lâu. Đây chính là một trong những thủ phạm kỹ thuật đứng sau cuộc khủng hoảng lặp lại (replication crisis) mà tâm lý học và y sinh học phải đối mặt suốt thập niên 2010.

Cách Grünwald và cộng sự giải quyết không phải là "vá lỗi" p-value, mà là thay hẳn đơn vị đo bằng chứng. Thay vì hỏi "xác suất quan sát được dữ liệu cực đoan như thế này dưới H_0 là bao nhiêu", e-value hỏi một câu khác hẳn: "nếu tôi đặt cược chống lại H_0 , tôi lãi được bao nhiêu lần vốn?" Về hình thức, một e-value E chỉ cần thỏa $\mathbb{E}_{\mathbb{P}}[E] \leq 1$ với mọi $\mathbb{P} \in \mathcal{H}_0$ — nói cách khác, dưới giả thuyết không, kỳ vọng của "tài sản cược" không được vượt quá vốn ban đầu. Điều tinh tế là ràng buộc này đúng *tại mọi thời điểm dừng*, kể cả thời điểm dừng chọn theo dữ liệu, nhờ định lý dừng tùy chọn áp dụng cho martingale/supermartingale không âm. Optional continuation không còn là gian lận nữa — nó được hợp thức hóa ngay trong định nghĩa.

Nhưng phần khó thật sự của bài báo không nằm ở việc định nghĩa e-value — điều đó tương đối quen thuộc với dân lý thuyết xác suất theo trường phái Ville và Shafer-Vovk từ trước đó. Cái khó là xây dựng một *tiêu chuẩn tối ưu* cho e-value khi giả thuyết đối không đơn giản mà là hợp phức (composite), thậm chí có tham số nhiều. Nhóm tác giả đề xuất Growth-Rate Optimality (GRO): trong số các e-value hợp lệ, chọn cái tối đa hóa tốc độ tăng trưởng log kỳ vọng dưới phân phối thật $\mathbb{Q}$,

$$\arg \max_E \mathbb{E}_{\mathbb{Q}}[\log E] \quad \text{s.t.} \quad \mathbb{E}_{\mathbb{P}}[E] \leq 1 \quad \forall \mathbb{P} \in \mathcal{H}_0.$$

Đây thực chất là bài toán đặt cược Kelly kinh điển được cấy ghép vào ngôn ngữ kiểm định giả thuyết — không phải trùng hợp, vì cả hai đều xuất phát từ cùng gốc rễ lý thuyết cược martingale của Ville. Điều khiến bài báo trở thành nền móng là chứng minh: e-value GRO, trong trường hợp giả thuyết đơn giản, chính là likelihood ratio; còn trong trường hợp hợp phức, nó tương đương với một Bayes factor sử dụng *prior tối ưu riêng cho mục đích kiểm định* — một prior không nhất thiết phản ánh niềm tin của người phân tích, mà được chọn thuần túy để tối đa hóa tốc độ tích lũy bằng chứng. Đây là cầu nối bất ngờ và đẹp giữa hai trường phái vốn thường coi là đối lập: tần suất luận (frequentist validity, vì e-value cho kiểm soát sai số loại I nghiêm ngặt) và cấu trúc Bayes factor.

Ảnh hưởng của bài báo lớn hơn nhiều so với một kết quả lý thuyết đơn lẻ. Nó cho cả lĩnh vực một *ngôn ngữ*: từ đây, "e-value", "e-process", "testing by betting" trở thành từ khóa chuẩn mà gần như mọi bài báo sau này trong SAVI (safe anytime-valid inference) đều dùng.

2. “Time-uniform Chernoff bounds via nonnegative supermartingales” (Howard, Ramdas, McAuliffe, & Sekhon, 2021)

Nếu Safe Testing cho ta *đơn vị* bằng chứng, bài báo này cho ta *công cụ hình học* để kiểm soát nó qua thời gian. Vấn đề xuất phát điểm rất cụ thể: một ranh giới tập trung kiểu Chernoff-Hoeffding — dạng $\mathbb{P}(|\bar{X}_N - \mu| > \epsilon) \leq \delta$ — chỉ đúng tại một N cố định được chọn trước khi nhìn dữ liệu. Nếu người dùng "peek" liên tục, so sánh $\bar{X}_t$ với ngưỡng ở mọi t và dừng lại ngay khi thấy có ý nghĩa, xác suất lỗi thực tế tăng vọt — về cơ bản đây là phiên bản concentration-inequality của chính vấn đề optional stopping ở trên.

Công cụ mà nhóm Howard-Ramdas dùng để giải là phương pháp hỗn hợp (method of mixtures): thay vì cố định một martingale mũ $\exp(\lambda S_t - \psi(\lambda)t)$ ứng với một tham số λ duy nhất, họ tích phân (hoặc lấy tổng rời rạc) trên một họ các martingale này theo một phân phối tiên nghiệm $\pi(\lambda)$. Kết quả — nhờ định lý Fubini và tính chất siêu martingale được bảo toàn dưới phép trộn — vẫn là một siêu martingale không âm, nhưng giờ nó "tự động" theo dõi được quỹ đạo tốt nhất

trên toàn bộ dải λ mà không cần biết trước λ tối ưu là bao nhiêu. Đây chính là mẹo kỹ thuật cho phép chuyển một Chernoff bound tĩnh thành một *chuỗi tin cậy* (confidence sequence) — một dải tin cậy C_t sao cho

$$\mathbb{P}(\forall t \geq 1, \mu \in C_t) \geq 1 - \alpha,$$

đúng đồng thời cho toàn bộ chuỗi thời gian vô hạn, chứ không phải chỉ đúng tại một t cố định.

Điều làm bài báo này khác biệt so với các nỗ lực trước đó (vốn cũng từng có, ví dụ trong lý thuyết bandit hay thống kê tuần tự cổ điển của Wald, Robbins) là độ chặt tiệm cận. Nhóm tác giả chứng minh các chuỗi tin cậy họ xây dựng co hẹp theo đúng tốc độ $O(\sqrt{t \log \log t})$ — bám sát quy luật loga lặp (law of the iterated logarithm), vốn được biết là tốc độ tối ưu không thể cải thiện thêm về mặt lý thuyết. Nói cách khác, cái giá phải trả để có được tính hợp lệ "mọi lúc" gần như là con số nhỏ nhất có thể — không phải đánh đổi bằng những ranh giới rộng thênh thang như union bound ngây thơ (áp Bonferroni theo từng t) sẽ cho ra.

Về mặt thực hành, đây là bài báo mà bất kỳ ai làm A/B testing công nghiệp quy mô lớn đều đặn tới, dù trực tiếp hay gián tiếp qua thư viện. Lý do rất thực dụng: các nền tảng thử nghiệm (Adobe Target, các hệ thống nội bộ ở Amazon, Netflix, Etsy...) không thể ép nhà phân tích cam kết trước cỡ mẫu — họ muốn xem dashboard theo thời gian thực và dừng bất cứ lúc nào cảm thấy đủ tín hiệu. Chuỗi tin cậy đồng nhất thời gian là công cụ toán học duy nhất cho phép việc đó mà không phá vỡ tỷ lệ lỗi loại I.

3. “Game-theoretic statistics and safe anytime-valid inference” (Ramdas, Grünwald, Vovk, & Shafer, 2023)

Đến năm 2023, hai dòng nghiên cứu trên — cùng với nhiều nhánh khác đến từ lý thuyết thông tin (universal coding, MDL), suy luận nhân quả tuần tự, và lý thuyết xác suất trò chơi của Shafer-Vovk từ những năm 2000 — đã phát triển song song trong nhiều năm, mỗi nhóm dùng một bộ thuật ngữ riêng, đôi khi phát minh lại cùng một kết quả dưới tên gọi khác. Bài báo này không đưa ra một kết quả kỹ thuật mới đột phá; giá trị của nó nằm ở việc là bản đồ tổng thể đầu tiên đặt tất cả dưới một mái nhà chung: “Thống kê Lý thuyết Trò chơi” (game-theoretic statistics).

Đóng góp cụ thể có thể chia làm ba lớp. Thứ nhất, về mặt định nghĩa, bài báo chuẩn hóa khái niệm e-process — một dãy (M_t) sao cho $M_t = \prod_{i=1}^t E_i$ với mỗi E_i là e-value điều kiện tại bước i , và chứng minh (M_t) là một supermartingale không âm dưới H_0 , từ đó suy ra ngay tính chất anytime-valid qua bất đẳng thức Ville (một dạng tổng quát hóa bất đẳng thức Markov cho supermartingale). Thứ hai, bài báo làm rõ mối quan hệ song ánh giữa ba đối tượng tưởng như khác nhau: e-process, chuỗi tin cậy, và thủ tục kiểm định tuần tự — chỉ ra rằng có được một cái, về nguyên tắc, xây được cả hai cái còn lại. Thứ ba, và có lẽ quan trọng nhất về mặt triết lý, họ đặt lại câu hỏi nền tảng: thay vì hỏi "dữ liệu này có phù hợp với H_0 không" (câu hỏi kiểu Neyman-Pearson tĩnh), hãy hỏi "nếu tôi đặt cược liên tục chống lại H_0 theo thời gian thực, tài sản của tôi tăng trưởng ra sao" — một sự dịch chuyển từ suy diễn thụ động sang một trò chơi tuần tự có tính chiến lược.

Chính khung nhìn "trò chơi tuần tự có chiến lược" này là bản lề khiến SAVI không dừng lại ở thống kê suy diễn nữa, mà mở đường tự nhiên sang các bài toán điều khiển: một khi đã coi thống kê là một quá trình đặt cược động theo thời gian, việc hỏi "Nên đặt cược bao nhiêu, khi nào nên dừng, khi nào nên hành động" chỉ còn cách bài toán điều khiển tối ưu kinh điển (optimal stopping, MDP) một bước rất ngắn. Đây chính là lý do các bài báo hiện đại 2025-2026 — về conformal risk control, về cây quyết định trực tuyến, về kiểm định nhảy thời gian — đều có thể coi là hệ quả trực tiếp, gần như tất yếu, của cách đặt vấn đề trong bài báo tổng hợp này.

1.11 Các nghiên cứu gần đây

Nếu các công trình nền tảng tập trung vào việc xây dựng e-value, kiểm soát tính hợp lệ theo thời gian và phát triển khung lý thuyết chung, các nghiên cứu gần đây bắt đầu đưa những ý tưởng này vào các hệ thống học máy và các bài toán ra quyết định trực tuyến. Trong các hệ thống như vậy, dữ liệu được thu thập liên tục và các quyết định có thể tạo ra hậu quả trực tiếp. Vì vậy, việc duy trì các bảo đảm thống kê trong quá trình vận hành trở nên đặc biệt quan trọng.

1. "Anytime-Valid Conformal Risk Control" (Hultberg, Zachariah, & Ribeiro, 2026)

Vấn đề thực sự nằm ở đâu. Conformal Risk Control (CRC) — phiên bản mở rộng của conformal prediction sang các hàm mất mát tổng quát hơn coverage — vốn đã cho một đảm bảo rất đẹp: rủi ro kỳ vọng trên phân phối biên (marginal risk) bị chặn dưới α . Nhưng "marginal" ở đây ẩn một điểm yếu chết người: đảm bảo đó lấy trung bình trên *tất cả các tập hiệu chuẩn có thể có*, chứ không phải đảm bảo cho tập hiệu chuẩn D_n cụ thể mà hệ thống đang thực sự nắm trong tay. Với một tập D_n xui xẻo — hoàn toàn có thể xảy ra do biến động ngẫu nhiên — xác suất rủi ro thực tế vượt α có thể lớn hơn nhiều so với con số α nghe có vẻ an toàn kia. Đây là khoảng cách giữa "an toàn trung bình" và "an toàn có điều kiện trên dữ liệu tôi đang có" — một khoảng cách vô hại trên giấy nhưng nguy hiểm thật khi hệ thống vận hành liên tục hàng tháng, hàng năm, và tập hiệu chuẩn liên tục được bổ sung online.

Cách họ dựng bài toán. Nhóm tác giả định nghĩa một họ tập dự đoán lồng nhau theo tham số λ (giống cấu trúc conformal risk control gốc của Angelopoulos et al.), với hàm mất mát $\ell(C_\lambda(X), Y) \in [0, B]$ đơn điệu theo λ . Cái mới không phải ở cấu trúc tập dự đoán, mà ở cách chọn ngưỡng vận hành λ_n : thay vì chọn λ_n sao cho rủi ro thực nghiệm trung bình $\leq \alpha$ (cách làm gốc, chỉ đúng ở kỳ vọng), họ cộng thêm một số hạng phạt γ_n xây dựng từ một siêu martingale phụ thuộc giả định sub-Gamma của phần dư mất mát, sao cho $\hat{R}_n(\lambda) + \gamma_n(\lambda) \leq \alpha$ giữ đúng đồng thời cho mọi n , không chỉ ở kỳ vọng. Về bản chất kỹ thuật, đây là một ứng dụng trực tiếp của cỗ máy chuỗi tin cậy Howard-Ramdas, nhưng áp lên rủi ro conformal thay vì lên trung bình mẫu thô.

Vì sao đáng chú ý. Cái giá phải trả cho tính "anytime-valid" ở đây không hề rẻ về mặt lý thuyết nhưng lại rất rẻ về mặt tốc độ hội tụ: hệ số phạt γ_n chỉ co hẹp theo $O(\sqrt{\log \log n/n})$ — chậm hơn $O(1/\sqrt{n})$ của phiên bản marginal đúng một thừa số $\log \log n$, gần như không đáng kể trong thực tế nhưng đổi lại có được đảm bảo mạnh hơn hẳn về chất. Điểm yếu thực sự nằm ở giai đoạn khởi động: cần một cỡ mẫu tối thiểu m^* trước khi tập dự đoán bắt đầu "có nghĩa" (non-vacuous, tức không suy biến thành toàn bộ không gian nhãn) — với các hệ thống mới triển khai, ít dữ liệu hiệu chuẩn, giai đoạn burn-in này có thể là một khoảng thời gian mà hệ thống gần như vô dụng về mặt thực tiễn dù vẫn "an toàn" về mặt lý thuyết. Đây cũng chính là lý do hướng mở tự nhiên của bài báo là selective conformal risk control — cho hệ thống quyền từ chối trả lời thay vì buộc phải đưa ra một tập dự đoán vô nghĩa trong giai đoạn burn-in.

2. "Correcting Split Selection in Online Decision Trees via Anytime-Valid Inference" (Amoukou, Mishra, & Veloso, ICML 2026)

Lỗi hổng nằm ở đâu trong Hoeffding Trees. Thuật toán cây quyết định trực tuyến kinh điển (Hoeffding Tree / VFDT) quyết định có nên chia một nút hay không bằng cách so sánh độ giảm rủi ro giữa hai lựa chọn chia nhánh tốt nhất, và dùng bất đẳng thức Hoeffding để ước lượng khoảng tin cậy cho chênh lệch đó. Vấn đề tinh tế nhưng nghiêm trọng: quyết định "có đủ bằng chứng để chia chưa" được đưa ra *sau khi* nhìn từng điểm dữ liệu mới đổ vào, tức thời điểm kiểm tra t phụ thuộc chính dữ liệu — lại đúng kiểu optional stopping đã nói ở phần trước, chỉ khác bối cảnh. Bất đẳng thức Hoeffding tĩnh không được thiết kế để chịu được việc bị "hỏi lại" liên tục như vậy; hệ quả là xác suất chia sai nhánh (false split), nếu để chạy đủ lâu, tiệm cận 1 chứ không dừng ở mức δ như thiết kế ban đầu nghĩ tưởng.

Cách sửa. Nhóm tác giả định nghĩa chênh lệch tổn thất giữa việc chia và không chia tại một ứng viên nhánh v với điểm cắt c :

$$\Delta_t^{v,c} = \ell(m_{t-1}^v(X_t), Y_t) - \ell(m_{t-1}^{v_c}(X_t), Y_t) \in [-1, 1],$$

rồi biến bài toán "có nên chia không" thành một bài toán kiểm định tuần tự betting-based: xây một e-process tích lũy bằng chứng cho giả thuyết " $\mathbb{E}[\Delta] > 0$ thực sự tồn tại" (tức chia có lợi thật, không phải nhiễu), và chỉ cho phép nút thực hiện chia (commit) khi e-process này vượt ngưỡng $1/\alpha$. Về cấu trúc, đây gần như một bản dịch trực tiếp của mô hình betting martingale sang bài toán chọn nhánh — cái khéo léo nằm ở việc chọn hàm cược (betting function) sao cho phù hợp với đặc thù non-stationary của luồng dữ liệu thực tế, chứ không giả định i.i.d cứng nhắc như Hoeffding Tree gốc.

Được và mất. Điểm được rõ ràng nhất là cây sinh ra gọn hơn — vì các nhánh chỉ được tạo khi thực sự có lợi thế dự đoán được xác nhận vững, thay vì bị nhiễu ngắn hạn đánh lừa — và độ chính xác tổng thể có xu hướng tăng nhẹ nhờ giảm overfitting cấu trúc cây. Cái mất là tốc độ phản ứng dưới concept drift nhanh: khi phân phối dữ liệu đổi đột ngột, ngưỡng an toàn nghiêm ngặt của e-process khiến cây do dự lâu hơn trước khi cập nhật cấu trúc, một đánh đổi giữa độ tin cậy thống kê và độ nhạy thích nghi — đây gần như là một dạng bias-variance tradeoff phiên bản tuần tự. Hướng mở đáng chú ý nhất, theo tôi, không phải là áp dụng sang pruning (khá tự nhiên, ít bất ngờ) mà là khả năng dùng chính cơ chế cược này làm tiêu chí dừng cho neural architecture search động — nơi bài toán "có nên thêm một nhánh/lớp mới" về cấu trúc toán học gần như y hệt bài toán "có nên chia nút" ở đây.

3. "Time-sensitive anytime-valid testing" (Clerico, Wegel, Azangulov, & Rebeschini, 2026)

Câu hỏi mà GRO bỏ sót. Toàn bộ lý thuyết SAVI từ Safe Testing trở đi tối ưu e-process theo tiêu chuẩn Growth-Rate Optimal (GRO) — tối đa hóa tốc độ tăng trưởng log kỳ vọng khi $t \rightarrow \infty$. Đây là tiêu chuẩn đúng nếu ta không quan tâm phát hiện sớm hay muộn, miễn cuối cùng phát hiện được. Nhưng trong rất nhiều ứng dụng thực — giám sát rủi ro hệ thống tài chính, phát hiện bất thường trong hạ tầng, tín hiệu giao dịch — một phát hiện đến sau một khoảng trễ dài gần như vô giá trị, dù về mặt thống kê nó vẫn "đúng". GRO tối ưu hóa cho một thế giới không có deadline; thế giới thực thì đầy deadline.

Cách đặt lại bài toán như điều khiển tối ưu. Nhóm tác giả gán một hàm phần thưởng $R(\tau)$ giảm dần (họ giả định giảm theo hàm mũ) theo thời điểm dừng/từ chối τ , biến bài toán chọn chiến lược cược tối ưu thành một bài toán Markov Decision Process với hai biến trạng thái duy nhất: thời gian trôi qua và "tài sản" (wealth) hiện có z của martingale cược. Phương trình Bellman tương ứng

$$v(z) = \max_{a \in A} \mathbb{E}_{\pi_1} [R(1) + v(z \cdot E(a, X))]$$

biến việc "chọn e-value tốt nhất ở mỗi bước" thành một bài toán điều khiển động cổ điển — điều mà GRO, vốn chỉ là một tiêu chuẩn tĩnh cho tốc độ tiệm cận, không bao giờ trực tiếp giải quyết được vì nó không có khái niệm "chiết khấu theo thời gian" (time discounting).

Điểm mấu chốt và giới hạn thực tế. Từ khung Bellman này họ rút ra tiêu chuẩn mới, Exponential-Decay-Optimal (EDO), và chứng minh trong trường hợp giả thuyết đơn giản (simple H_1), chiến lược cược tối ưu chính là e-process sinh từ thuật toán Neyman-Pearson tuần tự chặn hữu hạn — một kết quả khá thanh lịch vì nó nối lại với lý thuyết kiểm định tuần tự cổ điển của Wald từ những năm 1940, chỉ khác là bây giờ được diễn giải lại dưới ống kính điều khiển tối ưu hiện đại. Nhưng cái đẹp lý thuyết này khá mong manh khi rời khỏi giả thuyết đơn giản: với H_1 hợp phức — trường hợp phổ biến hơn nhiều trong thực tế, ví dụ không biết trước độ lớn hiệu ứng — phương trình Bellman không còn giải được dạng đóng, và bài báo thừa nhận đây là giới hạn chưa giải quyết, để ngỏ cho việc dùng deep RL xấp xỉ chính sách cược trên không

gian trạng thái liên tục. Nói cách khác, bài báo giải rất đẹp một trường hợp con, và biến trường hợp tổng quát thành một bài toán RL an toàn (safe RL) — một sự thừa nhận trung thực rằng cầu nối giữa SAVI và điều khiển tối ưu, dù đầy hứa hẹn, vẫn còn một khoảng cách kỹ thuật đáng kể chưa được lấp đầy.

1.12 Hạn chế và Các thách thức mở

- **Rò rỉ thông tin và cấu trúc nhân quả:** Khi nhiều e-process được chạy đồng thời, các quá trình có thể chia sẻ thông tin hoặc cùng phụ thuộc vào một bộ lọc chung. Việc kiểm soát tính hợp lệ trong trường hợp này phức tạp hơn so với một quá trình đơn lẻ. Một câu hỏi quan trọng là làm thế nào để duy trì tính anytime-valid khi các hệ thống có quan hệ phụ thuộc phức tạp hoặc tồn tại các biến gây nhiễu chưa được quan sát.
- **Dữ liệu không dừng và concept drift:** Các bảo đảm lý thuyết thường dựa trên một số giả định về quá trình sinh dữ liệu. Tuy nhiên, trong môi trường thực tế, phân phối dữ liệu có thể thay đổi theo thời gian. Một hướng nghiên cứu quan trọng là xây dựng các cơ chế thích nghi với concept drift mà không làm mất đi tính hợp lệ của e-process. Việc “quên” dữ liệu cũ có thể giúp hệ thống phản ứng nhanh hơn, nhưng cũng có thể phá vỡ các điều kiện cần thiết để duy trì bảo đảm martingale.
- **Kết hợp với Reinforcement Learning:** Việc đưa e-process vào bên trong các thuật toán học tăng cường vẫn còn nhiều thách thức. Một vấn đề quan trọng là làm thế nào để xây dựng các ranh giới anytime-valid cho các ước lượng giá trị và chính sách. Mục tiêu dài hạn là cho phép một tác tử học và tương tác với môi trường trong khi vẫn có thể kiểm soát rủi ro của các hành động chưa chắc chắn.
- **Không gian giả thuyết có chiều cao:** Trong các mô hình học máy hiện đại, không gian tham số có thể rất lớn. Việc xây dựng e-value tối ưu cho các giả thuyết rỗng phức tạp có thể đòi hỏi các bài toán tối ưu hóa tốn kém. Do đó, việc thiết kế các phương pháp gần đúng, có khả năng tính toán nhanh và vẫn giữ được bảo đảm thống kê là một hướng nghiên cứu quan trọng để AVC có thể được triển khai trong các hệ thống học máy quy mô lớn.

2 Counterfactual Safety Bound

2.1 Động lực

Phần lớn các phương pháp học máy và ra quyết định hiện đại, bao gồm cả học tăng cường, được thiết kế để tối ưu hóa một giá trị kỳ vọng trung bình trên toàn quần thể. Tuy nhiên, một chính sách có hiệu quả trung bình cao vẫn có thể tạo ra rủi ro nghiêm trọng đối với một nhóm cá thể cụ thể. Chẳng hạn, một phác đồ điều trị mới có thể cải thiện tỷ lệ sống sót chung, nhưng đồng thời làm xấu đi đáng kể kết quả của một nhóm bệnh nhân mà phác đồ cũ có thể phù hợp hơn.

Vấn đề này trở nên khó khăn hơn khi các kết quả của những quyết định chưa từng được thực hiện không thể quan sát trực tiếp. Dữ liệu quan sát chỉ cho biết điều gì đã xảy ra dưới một hành động cụ thể, chứ không cho biết cùng cá thể đó sẽ có kết quả như thế nào nếu nhận một hành động khác. Do đó, việc đánh giá một chính sách mới không chỉ là bài toán dự đoán giá trị trung bình, mà còn liên quan đến việc kiểm soát những hậu quả có thể xảy ra trong các kịch bản phản thực tế.

Từ nhu cầu này, các phương pháp thiết lập biên an toàn phản thực tế (Counterfactual Safety Bounds) được hình thành tại giao điểm của suy luận nhân quả, nhận dạng một phần và học chính sách an toàn. Thay vì cố gắng ước lượng một giá trị duy nhất khi dữ liệu không đủ để nhận dạng hoàn toàn hiệu ứng nhân quả, cách tiếp cận này tìm kiếm các cận trên và cận dưới tương thích với dữ liệu quan sát, dữ liệu thực nghiệm và các giả định nhân quả được chấp nhận. Một quyết định có thể được xem là an toàn nếu ngay cả trong các mô hình nhân quả bất lợi nhất nhưng vẫn phù hợp với dữ liệu, mức rủi ro của nó không vượt quá ngưỡng cho phép.

Hình dung đơn giản nhất là một “đa vũ trụ” toán học nhỏ. Quan sát một bệnh nhân uống thuốc rồi hồi phục không cho ta biết liệu họ có thực sự cần loại thuốc đó hay không, cũng như không biết điều gì sẽ xảy ra nếu họ nhận một phương án điều trị khác. Đây là biểu hiện của vấn đề cơ bản trong suy luận nhân quả: ta không thể quan sát đồng thời các kết quả tiềm năng của cùng một cá thể dưới những hành động khác nhau.

Tuy nhiên, ta vẫn có thể thu hẹp khoảng bất định bằng cách kết hợp nhiều nguồn thông tin, chẳng hạn dữ liệu quan sát và dữ liệu từ các thử nghiệm ngẫu nhiên. Nếu ngay cả cận trên của rủi ro vẫn nằm dưới ngưỡng cho phép, quyết định có thể được chứng nhận là an toàn theo nghĩa phản thực tế, dù giá trị chính xác của rủi ro không thể được xác định.

2.2 Counterfactual là gì?

Counterfactual (phản thực tế) mô tả kết quả có thể xảy ra nếu một hành động khác được thực hiện, trong khi các điều kiện nền của cùng một cá thể vẫn được giữ nguyên. Khái niệm này thường được đặt trong Thang Nhân quả (Ladder of Causation) do Judea Pearl đề xuất, gồm ba tầng từ thấp đến cao: Quan sát (Seeing), Can thiệp (Doing) và Phản thực tế (Imagining).

Ở tầng quan sát, học máy truyền thống chủ yếu làm việc với xác suất có điều kiện $P(y | x)$, trả lời câu hỏi: ‘Nếu quan sát thấy $X = x$, ta dự đoán Y như thế nào?’. Ở tầng can thiệp, toán tử $P(y | do(x))$ mô tả kết quả của việc chủ động đặt biến X thành giá trị x , tương ứng với câu hỏi: ‘Điều gì sẽ xảy ra nếu ta thực sự can thiệp để $X = x$?’.

Counterfactual đặt ra một câu hỏi mạnh hơn ở cấp độ cá thể: nếu một cá thể đã thực hiện hành động $X = x'$ và nhận kết quả $Y = y'$, thì điều gì sẽ xảy ra với chính cá thể đó nếu thay vào đó hành động $X = x$ được thực hiện? Điểm quan trọng của counterfactual là các kịch bản này

không được xem như những thế giới hoàn toàn độc lập. Chúng được liên kết thông qua các điều kiện nền chung của cùng một cá thể.

Trong mô hình nhân quả cấu trúc, một truy vấn phản thực tế thường được giải quyết qua ba bước:

1. **Suy diễn ngược (Abduction):** sử dụng thông tin quan sát được để suy luận về trạng thái của các biến ngoại sinh chưa quan sát;
2. **Hành động (Action):** thay thế cơ chế tạo ra biến điều trị bằng một can thiệp tương ứng với kịch bản giả định;
3. **Dự đoán (Prediction):** tính toán kết quả mới từ hệ phương trình cấu trúc sau khi can thiệp.

Việc duy trì các điều kiện nền chung giữa thế giới thực và thế giới giả định cho phép counterfactual mô tả các câu hỏi ở cấp độ cá thể, thay vì chỉ so sánh các giá trị trung bình giữa hai quần thể.

2.3 Mô hình Nhân quả Cấu trúc (SCM)

Mô hình Nhân quả Cấu trúc (Structural Causal Model - SCM) cung cấp một nền tảng toán học để mô tả cơ chế sinh dữ liệu và các quan hệ nhân quả. Một SCM thường được biểu diễn dưới dạng bộ tứ

$$[M = \langle V, U, F, P(U) \rangle,]$$

trong đó:

- V là tập các biến nội sinh (endogenous variables), đại diện cho các đại lượng được mô hình hóa và có thể quan sát;
- U là tập các biến ngoại sinh (exogenous variables), biểu diễn các yếu tố nền và nguồn ngẫu nhiên không được mô hình hóa trực tiếp;
- F là tập các phương trình cấu trúc mô tả cơ chế sinh ra các biến trong V ;
- $P(U)$ là phân phối xác suất trên các biến ngoại sinh.

Đối với mỗi biến $V_i \in V$, một phương trình cấu trúc có dạng

$$[v_i = f_i(pa(V_i), u_i),]$$

trong đó $pa(V_i)$ là tập các biến cha của V_i trong cấu trúc nhân quả và u_i đại diện cho các yếu tố ngoại sinh liên quan.

Các quan hệ giữa các biến trong F có thể được biểu diễn bằng một đồ thị nhân quả có hướng, thường là DAG trong trường hợp không có chu trình nhân quả. Một đặc điểm quan trọng của SCM là tính mô-đun. Khi thực hiện can thiệp $do(X = x)$, phương trình sinh ra X được thay thế bằng điều kiện $X = x$, trong khi các phương trình khác được giữ nguyên. Mô hình sau can thiệp được ký hiệu là M_x .

Tính mô-đun này cho phép phân biệt giữa cơ chế sinh dữ liệu trong thế giới thực và các thế giới được tạo ra bởi những can thiệp giả định. Vì vậy, SCM cung cấp nền tảng để xây dựng và phân tích các truy vấn can thiệp cũng như phản thực tế.

2.4 Kết quả Tiềm năng

Bên cạnh SCM, khuôn khổ Kết quả Tiềm năng (Potential Outcomes), thường gắn với mô hình Neyman–Rubin, cung cấp một cách biểu diễn khác cho suy luận nhân quả. Nếu X là biến điều trị và Y là kết quả, thì Y_x hoặc $Y(x)$ biểu diễn kết quả mà một cá thể sẽ nhận được nếu điều trị được đặt ở mức x .

Trong mối liên hệ với SCM, $Y_x(u)$ có thể được hiểu là nghiệm của biến Y trong mô hình sau khi thực hiện can thiệp $do(X = x)$, với điều kiện nền $U = u$ được giữ cố định. Tuy nhiên, đối với mỗi cá thể, dữ liệu thực tế chỉ cho phép quan sát kết quả tương ứng với hành động đã thực sự xảy ra. Các kết quả tiềm năng dưới những hành động khác không được quan sát trực tiếp.

Từ các kết quả tiềm năng, Hiệu ứng Can thiệp Trung bình (Average Treatment Effect - ATE) được định nghĩa là

$$[ATE = E[Y_1 - Y_0].]$$

ATE mô tả sự khác biệt trung bình giữa hai phương án điều trị trên toàn quần thể. Tuy nhiên, một giá trị ATE xác định không cho biết đầy đủ tác động của chính sách đối với từng cá thể. Khi tồn tại các biến nhiễu không quan sát được, phân phối chung của các kết quả tiềm năng có thể không được nhận dạng hoàn toàn từ dữ liệu. Trong trường hợp này, thay vì cố gắng xác định một giá trị duy nhất, các phương pháp Safety Bound tìm kiếm khoảng giá trị phù hợp với tất cả các ràng buộc dữ liệu và giả định nhân quả hiện có.

2.5 Do-calculus

Để liên kết dữ liệu quan sát với các phân phối can thiệp, Judea Pearl đã phát triển Do-calculus, một hệ thống các quy tắc đại số cho phép biến đổi các biểu thức xác suất chứa toán tử $do(\cdot)$. Các quy tắc này dựa trên quan hệ độc lập điều kiện và cấu trúc d-separation trong đồ thị nhân quả.

- **Quy tắc 1** cho phép chèn hoặc loại bỏ một biến quan sát khỏi điều kiện khi biến đó không cung cấp thêm thông tin nhân quả dưới cấu trúc đồ thị tương ứng:

$$P(y \mid do(x), z, w) = P(y \mid do(x), w).$$

- **Quy tắc 2** cho phép thay thế giữa một can thiệp và một quan sát trong những điều kiện đồ thị thích hợp:

$$P(y \mid do(x), do(z), w) = P(y \mid do(x), z, w).$$

- **Quy tắc 3** cho phép loại bỏ hoặc thêm một can thiệp khi can thiệp đó không còn ảnh hưởng đến biến kết quả dưới cấu trúc đồ thị đã được điều chỉnh:

$$P(y \mid do(x), do(z), w) = P(y \mid do(x), w).$$

Do-calculus đóng vai trò quan trọng trong việc xác định khi nào các phân phối can thiệp có thể được suy ra từ dữ liệu quan sát. Tuy nhiên, đối với nhiều truy vấn phản thực tế ở cấp độ cá thể, đặc biệt khi tồn tại các biến ngoại sinh chưa quan sát được, một giá trị duy nhất có thể không được nhận dạng. Đây là điểm mà các phương pháp thiết lập biên phản thực tế trở nên cần thiết.

2.6 Biên an toàn (Safety Bound)

Khi một đại lượng phản thực tế không thể được nhận dạng thành một giá trị duy nhất, tập hợp các mô hình nhân quả phù hợp với dữ liệu có thể chứa nhiều SCM khác nhau. Mỗi mô hình

trong tập hợp này có thể đưa ra một giá trị khác nhau cho đại lượng cần quan tâm. Tập hợp các giá trị có thể đạt được được gọi là tập hợp nhận dạng (identified set).

Với một hàm mục tiêu phản thực tế $g(M)$, các biên có thể được định nghĩa bởi

$$L = \inf_{M \in \mathcal{M}^*_{\text{adm}}} g(M), \quad U = \sup_{M \in \mathcal{M}_{\text{adm}}} g(M),$$

trong đó $\mathcal{M}_{\text{adm}}$ là tập các mô hình nhân quả phù hợp với dữ liệu quan sát, dữ liệu thực nghiệm và các giả định được chấp nhận. Khi đó, giá trị thực của đại lượng cần quan tâm được bảo đảm nằm trong khoảng $[L \leq g(M) \leq U]$.

Do đó, Safety Bound không cố gắng lựa chọn một SCM duy nhất trong số các mô hình có thể phù hợp với dữ liệu. Thay vào đó, nó đánh giá toàn bộ tập hợp các mô hình này và tìm ra các giới hạn của đại lượng phản thực tế. Tùy theo bài toán, cận dưới có thể được sử dụng để bảo đảm mức hiệu suất tối thiểu, trong khi cận trên có thể được sử dụng để kiểm soát rủi ro tối đa.

Trong các bài toán ra quyết định an toàn, một chính sách có thể được lựa chọn dựa trên hiệu suất tệ nhất trong tập hợp các mô hình tương thích. Chẳng hạn, nếu $V(\pi, M)$ là giá trị của chính sách π dưới mô hình nhân quả M , một tiêu chuẩn bi quan có thể được viết dưới dạng

$$\max_{\pi} \inf_{M \in \mathcal{M}_{\text{adm}}} V(\pi, M).$$

Cách tiếp cận này không loại bỏ hoàn toàn sự không chắc chắn do thiếu dữ liệu. Thay vào đó, nó đưa sự không chắc chắn đó trực tiếp vào quá trình ra quyết định, từ đó cho phép đánh giá liệu một chính sách có còn đạt mức hiệu suất hoặc an toàn tối thiểu trong những mô hình nhân quả bất lợi nhưng vẫn phù hợp với dữ liệu hay không.

2.7 Các công thức nền tảng

Nền tảng của Counterfactual Safety Bound được xây dựng trên một nhóm các đại lượng được gọi là Xác suất Nguyên nhân (Probabilities of Causation), định hình mối quan hệ giữa biến điều trị nhị phân X (với $x : X = 1, x' : X = 0$) và kết quả nhị phân Y .

Đại lượng trung tâm nhất là Xác suất Cần và Đủ (Probability of Necessity and Sufficiency - PNS), đo lường tỷ lệ các cá thể “chuyển đổi thực sự”, tức là những người sẽ thành công nếu được điều trị và sẽ thất bại nếu không được điều trị:

$$PNS = P(y_x, y'_{x'})$$

Thông qua định lý Tian-Pearl, PNS được giới hạn chặt chẽ bằng cách kết hợp thông tin quan sát và thực nghiệm (với $do(x)$ được viết gọn là y_x):

$$PNS \geq \max\{0, P(y_x) - P(y_{x'}), P(y) - P(y_{x'}), P(y_x) - P(y)\}$$

$$PNS \leq \min\{P(y_x), P(y'_{x'}), P(x, y) + P(x', y'), P(y_x) - P(y_{x'}) + P(x, y') + P(x', y)\}$$

Một đại lượng quan trọng không kém trong trách nhiệm pháp lý và y tế là Xác suất Cần thiết (Probability of Necessity - PN), trả lời câu hỏi: nếu không có X thì Y có xảy ra không, biết rằng thực tế cả X và Y đều đã xảy ra:

$$PN = P(y'_{x'} \mid x, y)$$

Biên toán học cho PN được tính bằng:

$$\max\left\{0, \frac{P(y) - P(y_{x'})}{P(x, y)}\right\} \leq PN \leq \min\left\{1, \frac{P(y'_{x'}) - P(x', y')}{P(x, y)}\right\}$$

Mở rộng lý thuyết này cho hệ thống Contextual Bandits phức tạp, nơi sự can thiệp phụ thuộc vào các hiệp biến C_1, C_2 , các nghiên cứu mới từ Bareinboim et al. đã đề xuất một nhóm các cận dưới tổng hợp (l_1 đến l_4) cho tác động nhân quả mục tiêu. Đáng chú ý nhất, công thức l_4 kết hợp cả dữ liệu quan sát và các phân phối can thiệp biên (marginal interventional distributions) để tạo ra một cận dưới sắc bén:

$$l_4(x, y, c_1, c_2) = P_x(y, c_1) - P_x(y, \neg c_2) + P(x, y, \neg c_1, \neg c_2)$$

Việc tính toán l_4 chứng tỏ rằng ngay cả dữ liệu từ các thử nghiệm ngẫu nhiên thiếu sót (ví dụ, thử nghiệm chỉ ghi nhận C_1 mà bỏ qua C_2) vẫn mang giá trị to lớn trong việc thắt chặt khoảng tin cậy của rủi ro.

2.8 Các định lý cơ bản

Việc thiết lập các biên an toàn phản thực tế không phải là các ước tính phỏng đoán, mà được bảo chứng bởi các định lý toán học chứng minh tính “chặt chẽ” (sharpness). Một biên được coi là chặt chẽ nếu không thể tìm ra một ranh giới nào hẹp hơn mà không loại trừ các mô hình dữ liệu hợp lệ.

Định lý quy hoạch tuyến tính Balke-Pearl (1994) là cơ sở quan trọng đầu tiên. Định lý này chứng minh rằng bất kỳ biến số phản thực tế nào trong một SCM rời rạc, dưới sự hiện diện của biến ẩn, đều có thể được ánh xạ đồng phôi thành tập nghiệm của một bài toán quy hoạch tuyến tính. Hàm mục tiêu tối ưu chính là tham số phản thực tế, và các ràng buộc đa diện là sự tương thích phân phối của mô hình với dữ liệu thực nghiệm và quan sát.

Định lý chặt chẽ Tian-Pearl (2000) tiếp bước bằng việc thiết lập các công thức dạng đóng (closed-form) cho Probabilities of Causation. Định lý này đảm bảo rằng các giới hạn của PNS, PN, và PS (nêu ở phần trên) là những giới hạn chặt chẽ nhất có thể đạt được từ việc kết hợp dữ liệu mà không cần thêm bất kỳ giả định nào về cơ chế nội bộ sinh ra dữ liệu.

Gần đây hơn, Định lý Tính Thống trị Biên kết hợp (Domination Theorem) của Joshi, Zhang và Bareinboim (2024) đưa ra một hệ quả quan trọng cho Học máy. Định lý này chứng minh rằng một biên kết hợp sự tương tác giữa dữ liệu quan sát và nhiều tập dữ liệu thực nghiệm cục bộ (như l_4) sẽ luôn luôn thống trị (chặt chẽ hơn hoặc bằng, không bao giờ lỏng hơn) các biên chỉ được xây dựng từ dữ liệu quan sát đơn thuần (như Manski bounds) trên mọi SCM tương thích. Sự thắt chặt này chính là chìa khóa để giảm bớt sự mơ hồ và tăng độ tin cậy của các quyết định AI.

2.9 Các giả định cốt lõi

Sức mạnh của Safety Bound tỷ lệ nghịch với số lượng giả định (assumptions) được đưa vào hệ thống; ít giả định hơn đồng nghĩa với biên rộng hơn và an toàn hơn, trong khi áp đặt nhiều giả định có thể thắt chặt biên nhưng làm tăng rủi ro vi phạm mô hình.

- **Tính Đơn điệu (Monotonicity):** Được định nghĩa toán học là $Y_x \geq Y_{x'}$ cho mọi cá thể, hay $y_x \wedge y'_{x'} = \text{false}$. Giả định này hàm ý điều trị có thể giúp ích hoặc không tác dụng, nhưng tuyệt đối không bao giờ gây hại. Dưới giả định này kết hợp với ngoại sinh, các khoảng bất định của Tian-Pearl hoàn toàn sụp đổ, hội tụ thành một ước tính điểm chính xác.
- **Không có biến nhiễu không quan sát được (No Unmeasured Confounders - NUC):** Định nghĩa là $Y_x \perp\!\!\!\perp X \mid C$. Phần lớn các thuật toán Safety Bound hiện đại được phát triển chính xác là để phủ nhận và hoạt động bất chấp sự vi phạm của giả định NUC này, đánh đổi việc mất đi nhận dạng điểm (point identification) để lấy sự vững chắc của các ranh giới.

- **Tính ngoại sinh mạnh (Strong Exogeneity):** Đòi hỏi cơ chế gán điều trị phải hoàn toàn độc lập với các biến ngoại sinh sinh ra kết quả, thường đạt được trong các thử nghiệm ngẫu nhiên có đối chứng lý tưởng.
- **Độ cong giới hạn (Curvature Sensitivity):** Đối với các biến liên tục, một giả định mới xuất hiện là giới hạn chuẩn của độ cong tập mức (level sets) của các phương trình cấu trúc, biểu thị bằng hằng số κ . Đây là nền tảng của Curvature Sensitivity Model nhằm thắt chặt biên cho biến liên tục mà không cần giả định tuyến tính.

2.10 Điều kiện áp dụng

Để triển khai được kiến trúc Counterfactual Safety Bound trong môi trường thực tiễn, cần thỏa mãn các điều kiện tiên quyết về dữ liệu và cấu trúc. Về mặt đồ thị, hệ thống yêu cầu sự tham gia của các chuyên gia lĩnh vực (domain experts) để phác thảo biểu đồ nhân quả có hướng (Causal DAG). Ngay cả khi đồ thị này không hoàn chỉnh, một lớp tương đương Markov (CPDAG) là bắt buộc để xác định vị trí của các biến nhiễu U tiềm ẩn.

Về khía cạnh dữ liệu, thuật toán yêu cầu các phân phối xác suất quan sát chung (joint observational distributions) với dung lượng mẫu đủ lớn để vượt qua nhiễu thống kê. Sức mạnh thắt chặt ranh giới được phát huy tối đa khi ta có thể thu thập thêm các tập dữ liệu từ các thử nghiệm ngẫu nhiên trong quá khứ, dù những thử nghiệm này chỉ ghi nhận thông tin cục bộ hoặc bị thiếu hụt hiệp biến (partial experimental data).

Về kiến trúc tính toán, các phương pháp quy hoạch tuyến tính (LP) thuần túy áp dụng hiệu quả nhất đối với các không gian biến rời rạc và mạng Bayesian nhiều nút phân loại. Khi cấu trúc đối mặt với dữ liệu liên tục như xử lý tín hiệu hay chuỗi thời gian, hệ thống bắt buộc phải tích hợp các công nghệ sinh học máy (Deep Generative Models, Normalizing Flows) hoặc tối ưu hóa xấp xỉ liên tục để có thể duy trì biên.

2.11 Hạn chế

Dù sở hữu sự vững chắc về mặt toán học, lý thuyết Counterfactual Safety Bound hiện đang đối diện với ba rào cản nghiêm trọng trong ứng dụng thực tiễn:

- **Khối lượng tính toán khổng lồ (Computational Intractability):** Theo hệ quả từ định lý Balke-Pearl, số lượng tham số phản thực tế trong bài toán quy hoạch tuyến tính tăng vọt theo cấp số nhân (độ phức tạp $\mathcal{O}(2^{2^n})$) dựa trên số lượng biến và các mức giá trị của chúng trong đồ thị. Điều này khiến việc tính toán các giới hạn chính xác tuyệt đối trên một DAG nhiều lớp trở thành bài toán NP-hard, làm giảm khả năng mở rộng (scalability).
- **Sự thiếu thông tin của biên (Uninformative Bounds):** Nếu đồ thị quá thừa thớt kiến thức ưu tiên, hoặc dữ liệu can thiệp bị thiếu hoàn toàn, các biên tính toán được (ví dụ như Manski bounds) thường kéo giãn từ 0 đến 1. Một biên có khoảng cách tuyệt đối như vậy mang lại mức độ chính xác toán học 100% nhưng giá trị thông tin là 0% đối với nhà quản trị trong việc ra quyết định.
- **Khó khăn trên không gian biến liên tục:** Đa số lý thuyết LP được xây dựng xung quanh phân phối rời rạc. Việc lập biên an toàn cho các biến liên tục đòi hỏi các kỹ thuật như tối ưu phi tuyến tính, hoặc phải dùng các giả định về độ nhạy độ cong (CSM). Việc phải thiết lập các tham số siêu việt (hyperparameters) này thường phụ thuộc vào đánh giá chủ quan, làm xói mòn tính trung lập phân phối (distribution-free) của hệ thống.

2.12 Các nghiên cứu kinh điển

Các tài liệu sau đã định hình khung khái niệm cốt lõi của toán học nhân quả và phương pháp lập biên, tạo ra trường phái suy luận mạnh mẽ thay thế cho mô hình thống kê tương quan truyền thống.

Tên bài báo	Tác giả & Năm	Đóng góp cốt lõi
Nonparametric bounds on treatment effects	Manski (1990)	Tiên phong trong lý thuyết Nhận dạng Một phần (Partial Identification). Chứng minh rằng nếu không có bất kỳ giả định bổ sung nào, hệ thống vẫn có thể được chặn bởi các ranh giới rộng nhất nhưng chính xác tuyệt đối (Manski Bounds), thay vì ngoại suy sai lệch.
Counterfactual Probabilities: Computational Methods, Bounds and Applications	Balke & Pearl (1994)	Xây dựng thuật toán đầu tiên dịch thuật các truy vấn phản thực tế SCM dưới sự ảnh hưởng của biến ẩn thành không gian tối ưu Quy hoạch Tuyến tính, đặt nền móng cơ học cho mọi thuật toán sinh biên hiện tại.
Probabilities of causation: Bounds and identification	Tian & Pearl (2000)	Phát triển các công thức đại số đóng chặt chẽ (sharp closed-form) nhằm giới hạn các Xác suất Nguyên nhân (PN, PS, PNS). Nghiên cứu chỉ ra thể mạnh của việc kết hợp dữ liệu quan sát và thử nghiệm ngẫu nhiên.
Causal Inference without Counterfactuals	Dawid (2000)	Bài báo mang tính phê bình (critical review) kinh điển, phân tách rạch ròi bài toán dự đoán hiệu ứng của một nguyên nhân (effects of causes) và suy đoán nguyên nhân của một hiệu ứng (causes of effects).
Causality: Reasoning, Inference Models, and	Pearl (2000/2009)	Cung cấp bộ khung Structural Causal Models (SCMs), ba quy tắc Do-calculus, và toàn bộ cơ sở đồ thị nhân quả phản thực tế.

2.13 Các nghiên cứu đương đại

Những nghiên cứu tiên phong trong vài năm trở lại đây tập trung vào việc giải quyết nút thắt về khả năng mở rộng thuật toán, không gian liên tục, và sự thất chặt biên an toàn để AI có thể trực tiếp ứng dụng.

Tên bài báo	Tác giả & Năm	Đóng góp cốt lõi
Towards Safe Policy Learning under Partial Identifiability: A Causal Approach	Joshi, Zhang, Bareinboim (2024)	Đề xuất giải pháp học máy an toàn bằng cách lập các phương trình biên kết hợp ($l_1 \dots l_4$) từ đa nguồn dữ liệu cục bộ. Chuyển hóa việc tính biên thành một thuật toán học tăng cường tối ưu hóa Maximin .
Robust Inference Decision Processes	Lally, Kazemi, Paoletti (2025/2026)	Thay thế các thuật toán tối ưu NP-hard bằng các công thức biên dạng đóng trực tiếp cho xác suất chuyển trạng thái. Giới thiệu mô hình MDP Khoảng (ICFMDP) và thuật toán Quy hoạch Bi quan (Pessimistic Value Iteration) .
Partial Identification of Continuous Outcomes with a Curvature Sensitivity Model	Melnychuk, Frauen, Feuerriegel (2023/2024)	Phá vỡ giới hạn truyền thống của các biến liên tục. Đề xuất Curvature Sensitivity Model (CSM) giới hạn độ cong của hàm và dùng mạng Normalizing Flows tạo sinh sâu (APID) để ước tính các biên phản thực tế .
Causal Identification from Counterfactual Data: Completeness and Bounding Results	Raghavan, Bareinboim (2025/2026)	Định nghĩa nguyên lý Realizability, giúp siết chặt khoảng bất định hơn nữa cho các truy vấn nhân quả phức tạp chưa thể nhận dạng .
Bounding Causal Effects and Counterfactuals	Maringgele (2025)	Hệ thống hóa toàn diện các kỹ thuật tính toán biên. Xây dựng thư viện mã nguồn mở CausalBoundingEngine kết hợp Entropy-regularized bounds .

2.13.1 Towards Safe Policy Learning under Partial Identifiability: A Causal Approach

Nghiên cứu của Joshi, Zhang, và Bareinboim giải quyết thách thức lớn trong học máy quyết định (đặc biệt là Contextual Bandits), nơi các thuật toán học chính sách (policy learning) hiện tại thường thiếu chính xác khi cố gắng suy luận tác động của một quy trình điều trị (treatment) mới từ những dữ liệu lịch sử bị nhiễu. Ý tưởng cốt lõi của bài báo là bác bỏ giả định “Không có biến nhiễu không quan sát được” (No Unmeasured Confounders - NUC). Thay vì chấp nhận rủi ro dự đoán sai, nhóm tác giả đề xuất việc khai thác đồng thời dữ liệu quan sát và các phân mảnh dữ liệu thực nghiệm (thử nghiệm ngẫu nhiên nhưng thiếu khuyết hiệp biến - partial experimental data) để tạo ra các vành đai bảo vệ. Mô hình toán học được xây dựng là một SCM với biến hành động X , phần thưởng Y , hiệp biến C_1, C_2 và biến nhiễu U .

Trong cấu trúc này, kỹ thuật counterfactual được sử dụng ở tầng sâu để nội suy và mô phỏng sự dịch chuyển phân phối phần thưởng: chuyện gì sẽ xảy ra đối với giá trị kỳ vọng của quần thể nếu hệ thống AI từ bỏ chính sách lịch sử để áp dụng một chính sách tham số hóa π mới. Khái niệm Safety Bound sau đó được triển khai trực tiếp vào vòng lặp huấn luyện; thay vì tối ưu hóa giá trị kỳ vọng theo một mô hình đơn lẻ thiếu cơ sở, thuật toán Maximin của tác giả sẽ tối đa hóa “cận dưới” của phần thưởng tương ứng với các kịch bản tồi tệ nhất tương thích với dữ liệu. Những cận dưới này được đúc kết qua bốn công thức biên l_1, l_2, l_3, l_4 . Nổi bật nhất là công thức:

$$l_4(x, y, c_1, c_2) = P_x(y, c_1) - P_x(y, \neg c_2) + P(x, y, \neg c_1, \neg c_2)$$

Đóng góp quan trọng của nghiên cứu là định lý thống trị tính toán (domination theorem), khẳng định bằng logic toán học rằng các biên hỗn hợp như l_4 luôn bao bọc chặt chẽ và an toàn hơn

các phương pháp cổ điển chỉ dựa trên quan sát. Phương pháp này có lợi thế lớn về tốc độ: do biên được biểu diễn dưới dạng công thức đóng (sharp, closed-form formulas), mô hình học sâu có thể lan truyền ngược (backpropagate) qua hàm mất mát cực nhanh mà không cần liên tục giải các bài toán quy hoạch tuyến tính lớn. Tuy nhiên, hạn chế của khung lý thuyết này là sự phụ thuộc vào dữ liệu biến rời rạc và yêu cầu phải có các mảnh dữ liệu thực nghiệm (marginal experimental distributions).

2.13.2 Robust Counterfactual Inference in Markov Decision Processes

Công trình của Lally, Kazemi và Paoletti tập trung vào một hạn chế lớn của Đánh giá Chính sách Ngoại tuyến (Offline Policy Evaluation) cho chuỗi quyết định động: sự không chắc chắn của mô hình nhân quả ẩn trong quá trình Markov Decision Processes (MDPs). Khi mô phỏng một phản thực tế để đánh giá chính sách mới, các phương pháp hiện tại (như mô hình Gumbel-Max SCM) thường giả định một hệ thống SCM cụ thể một cách chủ quan. Điều này mang lại rủi ro cao vì có nhiều mô hình SCM khác nhau có thể cùng sinh ra phân phối MDP quan sát được nhưng lại rẽ nhánh thành vô số phân phối phản thực tế riêng biệt, làm giảm độ hợp lệ (validity) của kết quả. Ý tưởng của nhóm tác giả là dừng việc cố gắng chọn một SCM duy nhất. Thay vào đó, họ tìm kiếm các ranh giới chặt chẽ (tight bounds) trên xác suất chuyển đổi phản thực tế và xây dựng một cấu trúc liên kết gọi là Interval Counterfactual MDP (ICFMDP).

Mô hình toán học của họ là một quá trình chuỗi Markov $M = (S, A, P, P_I, R)$, trong đó hàm chuyển dịch trạng thái được mô tả thành một phương trình cấu trúc nhân quả SCM: $S_{t+1} = f(S_t, A_t, U_t)$. Suy luận counterfactual ở đây được áp dụng ở cấp độ vi mô của từng quỹ đạo (trajectory): nó ước lượng xác suất hệ thống sẽ chuyển sang trạng thái mới s' nào nếu ở quá khứ, thuật toán đã thực hiện hành động giả định $\tilde{a}$ thay vì hành động a_t đã thực sự được ghi lại. Thay vì sử dụng một số thực tĩnh, Safety Bound biến xác suất chuyển đổi này thành một khoảng tin cậy $[P_{LB}, P_{UB}]$, ví dụ như:

$$P_{LB} = \max \left(0, P(\tilde{y}_i | \tilde{x}_j) - \frac{1 - P(y_k | x_p)}{P(y_k | x_p)} \right)$$

Khi không gian khoảng này được thiết lập, thuật toán Pessimistic Value Iteration (Quy hoạch động bi quan) được sử dụng để lọc ra chính sách an toàn nhất.

Đóng góp nổi bật của công trình là việc tìm ra công thức đại số dạng đóng cho xác suất chuyển đổi MDP, loại bỏ yêu cầu giải phương trình quy hoạch tuyến tính (Linear Programming) có số lượng biến lớn. Phương pháp này giúp tăng tốc độ đáng kể, từ 4 đến 251 lần so với phương pháp lấy mẫu Gumbel-Max truyền thống, đồng thời cung cấp đảm bảo an toàn. Tuy nhiên, phương pháp tiếp cận quy hoạch bi quan (Pessimistic) có thể dẫn đến việc tạo ra một chính sách quá thận trọng (over-conservative).

2.13.3 Partial Counterfactual Identification of Continuous Outcomes with a Curvature Sensitivity Model

Các nhà nghiên cứu Melnychuk, Frauen và Feuerriegel tập trung vào một trong những thách thức khó khăn nhất của Partial Identification: Biến liên tục (Continuous Outcomes). Khi áp dụng các kỹ thuật tính toán biên truyền thống (chỉ dành cho không gian phân loại rời rạc) lên các đại lượng kết quả liên tục, khoảng bất định (ignorance interval) thường trải dài từ âm vô cực đến dương vô cực (non-informative bounds), không mang lại giá trị thực tiễn. Nhóm tác giả đã đề xuất rằng buộc toán học “độ cong” (curvature) của các tập mức (level sets) trong hệ phương trình, sinh ra khái niệm Curvature Sensitivity Model (CSM).

Mô hình toán học được xây dựng là một hệ thống SCM hai biến (bivariate) với điều trị X và kết quả Y nằm trên phổ liên tục. Họ tính toán các tích phân Hausdorff dưới điều kiện đạo hàm

không gian bị giới hạn bởi một hằng số độ cong κ . Truy vấn counterfactual được giải quyết ở đây là ECOU (Expected Counterfactual Outcome of [Un]Treated). Cận dưới của ECOU sau khi giới hạn độ cong nếu vẫn lớn hơn 0, phương pháp điều trị đó được xem là có hiệu quả bất chấp các biến nhiễu chưa đo được. Tác giả đề xuất mạng nơ-ron tạo sinh APID (Augmented Pseudo-Invertible Decoder) sử dụng kỹ thuật Residual Normalizing Flows tích hợp trực tiếp tham số mật độ cong.

CSM là mô hình Sensitivity Model đầu tiên cho suy luận phản thực tế với kết quả liên tục (khi đặt $\kappa = 0$, CSM thu gọn về Bijective Generative Mechanisms). Ưu điểm của CSM là tránh được việc phải rời rạc hóa dữ liệu (discretization) gây sai lệch thông tin và tích hợp thành công vào kiến trúc Deep Learning hiện đại. Dù vậy, việc thiết lập hằng số độ cong κ đòi hỏi kiến thức chuyên môn đặc thù; nếu κ được cấu hình sai lệch, ranh giới an toàn có thể không còn ý nghĩa.

2.14 Các thách thức mở

Dù lĩnh vực toán học suy luận nhân quả và giới hạn an toàn đã có những bước tiến đáng kể, một số thách thức nghiên cứu vẫn đang đặt ra cho các nhà khoa học máy tính:

- **Khả năng mở rộng cho dữ liệu cao chiều (Scalability to High-dimensional Data):** Bất chấp các kỹ thuật tối ưu hóa phi tuyến Semi-definite Programming (SDP), khi số lượng các hiệp biến (covariates) và mức độ phân loại mở rộng, việc tính toán vẫn gặp hạn chế. Việc tìm ra các thuật toán xấp xỉ biên tối ưu (entropy-regularized bounds) mang tính lý thuyết thông tin sâu hơn vẫn là một mục tiêu lớn.
- **Đối phó với động học phi tĩnh và không Markov (Non-Markovian Dynamics):** Nền tảng của SCM và MDP hiện tại phụ thuộc vào cấu trúc hướng không chu trình và giả định Markov (độc lập tuyệt đối của các yếu tố ngoại sinh U). Trong thế giới thực với sự tương quan phản hồi vòng lặp (feedback loops), cần phát triển một khung toán học mới cho các hệ thống thời gian động (dynamical systems).
- **Sự tích hợp với Mô hình Ngôn ngữ Lớn (LLM Integration):** Xu hướng dùng LLMs để tự động trích xuất các đồ thị nhân quả và tạo các tri thức nền đối mặt với rủi ro từ hiện tượng ảo giác (hallucination) của LLMs. Việc chứng minh tính toàn vẹn và độ tin cậy của việc lai ghép giữa suy luận nhân quả và LLMs là một hướng đi tiềm năng nhưng vẫn còn nhiều rủi ro.
- **Điều trị Liên tục và Linh hoạt (Continuous & Dynamic Treatments):** Việc duy trì các ranh giới an toàn cho các tác động điều trị động học (như điều chỉnh liều lượng thuốc theo thời gian thực) vẫn thiếu hụt các định lý hội tụ. Làm thế nào để cân bằng giữa sự giới hạn của cận dưới phản thực tế và tính hiệu quả trong việc thử nghiệm các chiến lược của Học Tăng Cường (Reinforcement Learning) vẫn là câu hỏi định hình tương lai của AI An toàn.

3 Causal Reinforcement Learning

3.1 Động lực và Trực giác

Học tăng cường (RL) truyền thống vốn vận hành dựa trên việc thử-và-sai để tìm ra mẫu hình tương quan. Chẳng hạn, mô hình thấy "trời mưa" thường đi kèm "giảm tốc", nên nó học cách tự động phanh gấp cả khi mặt đường đang khô ráo. Nó gán nhãn sai nguyên nhân. RL truyền thống vướng phải hai rào cản lớn:

- **Thiên lệch do biến nhiễu (Confounding bias):** Khi học từ dữ liệu ngoại tuyến (offline RL), nếu có một biến ẩn chi phối cả hành động của chuyên gia lẫn kết quả, mô hình sẽ học các tương quan giả thay vì cơ chế thực tế.
- **Mù mờ về phản thực tế (Counterfactual reasoning):** RL truyền thống không có năng lực tự đặt câu hỏi: "Nếu bối cảnh đó lặp lại và mình chọn hành động khác, kết quả sẽ thay đổi ra sao?".

Lấy một ví dụ dễ hình dung: RL giống như một người học lái xe bằng cách cố ghi nhớ từng khung cảnh lướt qua cửa kính, còn Causal RL (CRL) giống như người hiểu được rằng việc đạp ga (nguyên nhân) mới làm bánh xe lăn (kết quả). Nhờ được trang bị "lăng kính nhân quả", CRL có thể bóc tách đâu là tác động cơ học thực sự, đâu chỉ là sự trùng hợp ngẫu nhiên.

3.2 Ba lĩnh vực

- **Standard RL:** tối ưu $\max_{\pi} \mathbb{E}_{\pi}[\sum \gamma^t R_t]$, ngầm coi $P(Y | X)$ là tác động cơ học của X lên Y .
- **Causal Inference:** tách tương quan thành hiệu ứng nhân quả qua toán tử $(X = x)$, mục tiêu nhận dạng $P(Y | (X = x))$.
- **Causal RL:** nhúng MDP vào Structural Causal Model (SCM) theo thời gian; A_t là can thiệp (A_t) cắt đứt liên kết từ quá khứ; mục tiêu $\mathbb{E}[\sum \gamma^t R_t | (\pi)]$.

Đặc tính	Standard RL	Causal Inference	Causal RL
Dữ liệu	Chuỗi (S, A, R, S')	Tĩnh (i.i.d)	Chuỗi thời gian + SCM
Toán tử cốt lõi	$P(\cdot \cdot)$	$(\cdot)$	$\mathcal{T}_c^{\pi}$
Mục tiêu	$\max_{\pi} \mathbb{E}[R A \sim \pi]$	nhận dạng $P(Y (X))$	$\max_{\pi} \mathbb{E}[R (A \sim \pi)]$
Giả định	Markov, Positivity, NUC ngầm	Causal Markov, Faithfulness	Causal Markov, Seq. Ignorability
Xử lý nhiễu ẩn	Thất bại	Backdoor/Frontdoor	Bound Q / Causal Discovery

3.3 Nền tảng toán học

MDP: $\mathcal{M} = \langle S, \mathcal{A}, P, R, \gamma, \rho_0 \rangle$, với $P(s' | s, a)$ là kernel chuyển tiếp thuần thống kê, không mang cơ chế sinh.

SCM: $\mathcal{M}_C = \langle \mathbf{V}, \mathbf{U}, \mathbf{F}, P(\mathbf{U}) \rangle$, biến nội sinh $\mathbf{V}$, ngoại sinh $\mathbf{U}$, và

$$v_i = f_i(pa_i, u_i),$$

với pa_i là nguyên nhân trực tiếp. Toàn bộ ngẫu nhiên của $\mathbf{V}$ đến từ $P(\mathbf{U})$.

Causal Graph $\mathcal{G}$: DAG trên $\mathbf{V} \cup \mathbf{U}$, mã hóa độc lập có điều kiện qua d -separation.

Intervention: $(X = x)$ thay phương trình cấu trúc của X bằng hằng số, xóa mọi cạnh vào X . Kết quả $P(Y \mid (X = x)) \neq P(Y \mid X = x)$ nói chung.

Potential Outcome: $Y(x)$ — nghiệm của Y trong SCM phụ $\mathcal{M}_x$.

Counterfactual: $Y_{X=x'}(u)$ — kết quả nếu $(X = x')$ trong bối cảnh $\mathbf{U} = u$ đã nội suy từ quan sát thực tế. Chuỗi bậc thang: *Association* (MDP) $\rightarrow$ *Intervention* $\rightarrow$ *Counterfactual*.

3.4 Causal MDP

$$\mathcal{M}_C = \langle \mathcal{S}, \mathcal{A}, \mathcal{U}, \mathbf{F}, P(\mathcal{U}), \gamma \rangle$$

Hệ phương trình cấu trúc tại bước t :

$$S_{t+1} = f_S(S_t, A_t, U_t), \quad R_t = f_R(S_t, A_t, U_t), \quad A_t = f_A(S_t, U_t)$$

($A_t = f_A(S_t, U_t)$ áp dụng khi dữ liệu sinh từ chính sách hành vi bị nhiễu.)

Observational transition:

$$P(S_{t+1} = s' \mid S_t = s, A_t = a) = \int_{\mathcal{U}} \mathbb{I}_{s'=f_S(s,a,u)} P(u \mid S_t = s, A_t = a) du$$

Interventional transition (cắt cạnh $U_t \rightarrow A_t$):

$$P(S_{t+1} = s' \mid S_t = s, (A_t = a)) = \int_{\mathcal{U}} \mathbb{I}_{s'=f_S(s,a,u)} P(u \mid S_t = s) du$$

Về đầu học confounding bias; về sau tách đúng động học cơ học. Mục tiêu Causal RL là tối ưu trên chuyển tiếp can thiệp.

3.5 Intervention và Counterfactual trong RL

Action intervention: $(A_t = a)$ — ép giá trị hành động, xác suất mọi giá trị khác bằng 0.

Policy intervention: (π) trên quỹ đạo $\tau = (s_0, a_0, r_0, \dots, s_T)$:

$$P_{(\pi)}(\tau) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi(a_t \mid s_t) P(s_{t+1} \mid s_t, (a_t)) P(r_t \mid s_t, (a_t))$$

Counterfactual action & trajectory: quy trình ba bước Abduction–Action–Prediction.

1. *Abduction:* $P(U_t = u \mid s_t, a_t, r_t, s_{t+1})$ (Bayes).
2. *Action:* áp ($A_t = a'$).
3. *Prediction:* $S_{t+1,a'}(u) = f_S(s_t, a', u)$, tạo τ_{cf} .

Counterfactual reward: $R_{t,a'}(u) = f_R(s_t, a', u)$ — đo thay đổi phần thưởng khi chỉ hành động đổi, giữ nguyên u đã xảy ra.

Ba tầng: Observation ("thực tại đã xảy ra thế nào"), Intervention ("thế giới chung phản ứng ra sao"), Counterfactual ("bối cảnh cụ thể này sẽ khác thế nào nếu quyết định khác").

3.6 Causal Decision-Making

Interventional value:

$$V^\pi(s) = \mathbb{E}_{P(\pi)} \left[\sum_{t=0}^{\infty} \gamma^t R_t \mid S_0 = s \right]$$

Counterfactual value: $V_{cf}^\pi(s \mid u)$ — kỳ vọng phần thưởng dưới π khi $U = u$ đã biết, loại bỏ phương sai aleatoric.

Causal effect (ATE dạng RL):

$$CE(s, a_1, a_0) = Q^\pi(s, a_1) - Q^\pi(s, a_0)$$

Causal advantage: so với hành động gốc a_{def} tại cùng $U = u$:

$$A_{cf}(s, a, u) = R_{cf}(s, a, u) + \gamma V_{cf}^\pi(S_{cf}(s, a, u)) - \left(R_{cf}(s, a_{def}, u) + \gamma V_{cf}^\pi(S_{cf}(s, a_{def}, u)) \right)$$

Cô lập $U = u$ cho gradient chính sách không chệch, phương sai thấp.

Causal regret:

$$\mathcal{R}_c(T) = \sum_{t=1}^T \left(V^{\pi^*}(s_t) - V^{\pi_t}(s_t) \right)$$

có thể đạt cận $\mathcal{O}(\sqrt{T})$ với hệ số chặt hơn nhờ thu hẹp không gian thăm dò bằng đồ thị nhân quả.

3.7 Khung công thức thống nhất

Causal transition (g-formula), khi $\mathbf{Z}$ thỏa Backdoor:

$$P(s', r \mid s, (a)) = \sum_{z \in \mathcal{Z}} P(s', r \mid s, a, z) P(z \mid s)$$

Counterfactual return:

$$G_{cf}(t) = \sum_{k=t}^{\infty} \gamma^{k-t} R_{cf}(k \mid u)$$

Causal Bellman Equation:

$$(\mathcal{T}_c^\pi V)(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) \sum_{s', r} P(s', r \mid s, (a)) [r + \gamma V(s')]$$

Không nhiễu ($P(\cdot \mid (a)) = P(\cdot \mid a)$) thì thu về Bellman chuẩn.

Causal Bellman Optimality Bound (Confounded MDP, Zhang & Bareinboim):

$$Q^*(s, x) \geq \min_U \left(P(x \mid s) (\mathbb{E}_U[\tilde{R}] + \gamma \mathbb{E}_U[\max_{x'} Q^*(s', x')]) + P(\neg x \mid s) (a_{min} + \dots) \right)$$

Tối ưu bảo thủ theo kịch bản xấu nhất của U .

Causal policy evaluation: $V_{k+1} = \mathcal{T}_c^\pi V_k$, hội tụ cho ước lượng Causal Regret — biến exploration thành thu hẹp bất định nhân quả.

3.8 Định lý và điều kiện nhận dạng

- **Causal Markov Condition:** một biến độc lập với các non-descendants khi điều kiện trên tập cha — biện minh việc tách S_{t+1} khỏi $S_{0:t-1}$.
- **Backdoor Criterion:** Z không chứa hậu duệ của A và phong tỏa mọi đường có mũi tên vào $A \Rightarrow$ nhận dạng qua công thức điều chỉnh.
- **Frontdoor Criterion:** tồn tại biến trung gian M trên đường $A \rightarrow Y$, nhiễu ẩn không tác động M :

$$P(y | (a)) = \sum_m P(m | a) \sum_{a'} P(y | m, a') P(a')$$

- **Do-Calculus:** ba quy tắc của Pearl chuyển đổi giữa xác suất quan sát và can thiệp — đầy đủ (complete) cho bài toán Identification.
- **Sequential Ignorability** (Robins), cho Dynamic Treatment Regimes:

$$Y(\bar{a}) \perp\!\!\!\perp A_t \mid \bar{A}_{t-1} = \bar{a}_{t-1}, \bar{S}_t = \bar{s}_t$$

Sau khi điều kiện trên lịch sử, A_t độc lập với kết quả tiềm năng tương lai — hành vi quan sát "như thể ngẫu nhiên hóa".

3.9 Các giả định

- **Markov:** $S_{t+1} \perp\!\!\!\perp H_{t-1} \mid S_t, A_t$. Vi phạm $\Rightarrow$ đệ quy Bellman phân kỳ.
- **No Unmeasured Confounding / Sequential Ignorability:** mọi Z điều khiển chung (A, S') đều đo được. Vi phạm $\Rightarrow$ Confounded MDP, bất khả nhận dạng.
- **Positivity:** $P(A_t = a \mid S_t = s) > \epsilon > 0$. Vi phạm $\Rightarrow$ IPW mẫu số $\rightarrow 0$, phương sai bùng nổ.
- **Consistency:** $A = a \implies Y = Y(a)$.
- **Stationarity:** $\mathbf{F}$ và $P(\mathbf{U})$ không trôi theo thời gian.
- **Correct Causal Graph:** sai lệch cạnh $\Rightarrow$ Backdoor/Frontdoor thất bại, điều chỉnh nhằm collider.

3.10 Điều kiện áp dụng

- **Confounding** (Offline RL): dữ liệu môi giới/chuyên gia có thông tin mật U ảnh hưởng cả quyết định lẫn kết quả — cần bounding/deconfounding.
- **Distribution shift:** Causal Invariance giữ cơ chế cục bộ (vd. vật lý bám đường) bất biến qua bối cảnh $\Rightarrow$ zero-shot generalization.
- **Sequential decision-making** (Healthcare/DTR): Sequential Ignorability xử lý thiên lệch bác sĩ trong lịch sử điều trị.
- **Counterfactual reasoning:** tách kỹ năng khỏi may rủi trong credit assignment.

3.11 Hạn chế lý thuyết

- **Hidden confounding / Unidentifiability:** khi NUC sụp đổ và Backdoor/Frontdoor không đủ, chỉ có partial identification bounds.
- **Misspecified causal graph:** Causal Discovery từ dữ liệu tương tác chiều cao là NP-Hard, dữ liệu non-i.i.d.
- **Partial observability:** kết hợp POMDP–SCM chưa có đại số tường minh tách trạng thái ẩn do cảm biến nhiễu biến nhiều.
- **Long-horizon effects:** $T \rightarrow \infty$ khiến trọng số IPW tích lũy sai số, phương sai counterfactual evaluation vô hạn.
- **Continuous action spaces:** tích phân do-calculus bất khả thi tính toán, cần Flow-matching/Diffusion cho Abduction, chi phí lớn.

3.12 Ví dụ minh họa

Lĩnh vực	S_t, A_t	Nhiều U_t	(A_t) / Counterfactual
Xe tự hành	Tốc độ, vật cản / Phanh, lái	Độ bám đường	(Phanh) đo gia tốc thuần cơ học; CF: "phanh sớm hơn 1s với đúng độ trơn hôm đó, có tránh tai nạn?"
Robotics	Tọa độ tay / Lực kẹp	Khối lượng, độ giòn vật thể	(Kẹp) áp lực độc lập cảm biến nhiễu; CF: "với trọng lượng thực u , lực $F' = 10N$ có làm vỡ?"
Y tế (DTR)	Chỉ số sinh tồn / Liều thuốc	Gen, dinh dưỡng	(Thuốc) tác động được lý thực; CF: "không dùng thuốc tuần trước, huyết áp hôm nay ra sao?"
Gợi ý ND	Lịch sử xem / Đề xuất	Trending, tâm trạng	(Gợi ý) đo gắn kết thuần; CF: "đề xuất B thay A, người dùng có click?"
Thương mại	Tồn kho, giá đối thủ / Định giá	Cú sốc nguồn cung	(Giảm giá) hiệu ứng biên lên nhu cầu; CF: "giữ giá lúc khan hiếm, lợi nhuận ra sao?"

3.13 Các thách thức mở

- Bounding mechanism cho Causal Bellman trong offline RL nhiễu nặng mà không phá hủy hiệu năng chính sách.
- Causal discovery trên dữ liệu non-stationary song song với policy optimization — hội tụ chưa được chứng minh.
- Long-horizon counterfactual reasoning: sai số Abduction lan truyền theo cấp số nhân; cần cơ chế attention mang tính nhân quả.
- Lý thuyết đại số thống nhất cho POMDP + Causal RL; do-calculus khả thi cho continuous action.

- **Unified theory:** kết nối hình học vi phân SCM, đại số Bellman Operators, Transportability và logic phản thực tế trong một không gian Hilbert.

Tài liệu tham khảo

- [1] Ville, J. (1939). *Étude critique de la notion de collectif*. Gauthier-Villars, Paris.
- [2] Wald, A. (1945). Sequential Tests of Statistical Hypotheses. *Annals of Mathematical Statistics*.
- [3] Darling, D. A., & Robbins, H. (1967). Iterated Logarithm Inequalities. *Proceedings of the National Academy of Sciences*.
- [4] Shafer, G., & Vovk, V. (2001). *Probability and Finance: It's Only a Game!*. Wiley.
- [5] Ramdas, A., Ruf, J., Larsson, M., & Koolen, W. (2020). Admissible Anytime-Valid Sequential Inference Must Rely on Nonnegative Martingales.
- [6] Howard, S. R., Ramdas, A., McAuliffe, J., & Sekhon, J. (2021). Time-uniform, Nonparametric, Nonasymptotic Confidence Sequences. *Annals of Statistics*.
- [7] Hultberg, E., Zachariah, D., & Ribeiro, M. (2026). Anytime-Valid Conformal Risk Control.
- [8] Khosravi, B., & Huo, X. (2026). Conformal Selective Acting.
- [9] Balke, A., & Pearl, J. (1994). Counterfactual Probabilities: Computational Methods, Bounds, and Applications. *Uncertainty in Artificial Intelligence (UAI)*.
- [10] Tian, J., & Pearl, J. (2000). Probabilities of Causation: Bounds and Identification. *Annals of Mathematics and Artificial Intelligence*.
- [11] Manski, C. F. (1990). Nonparametric Bounds on Treatment Effects. *American Economic Review*.
- [12] Li, Y., Wu, T., & Shi, C. (2026). Counterfactually Safe Reinforcement Learning.
- [13] Khosravi, B., & Huo, X. (2026). *CausalBoundingEngine*.
- [14] Bareinboim, E., Forney, A., & Pearl, J. (2015). Bandits with Unobserved Confounders: A Causal Approach. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [15] Zhang, J., & Bareinboim, E. (2016). Markov Decision Processes with Unobserved Confounders: A Causal Approach.
- [16] Shpitser, I., & Pearl, J. (2006). Identification of Joint Interventional Distributions in Recursive Semi-Markovian Causal Models. *AAAI*.
- [17] Deng, Z., Jiang, J., et al. (2023). Causal Reinforcement Learning: A Survey.
- [18] Lu, C., et al. (2025). Causal Process Models (CPMs).
- [19] Khosravi, B., & Huo, X. (2026). CausalPPO and CAE-PPO: Causal Deconfounding for Continuous Control.