

Báo cáo Chuyên sâu: Biểu diễn Tiềm ẩn (Latent Representation) trong Hệ thống Lái xe Tự động

Ngày 22 tháng 7 năm 2026

Tóm tắt nội dung

Hệ thống lái xe tự động (Autonomous Driving - AD) đang chuyển dịch mạnh mẽ sang các phương pháp tiếp cận học từ đầu đến cuối (end-to-end learning) dựa trên Mô hình Thế giới (World Models). Trái tim của sự chuyển dịch này chính là Không gian Biểu diễn Tiềm ẩn (Latent Representation Space). Tài liệu này được cấu trúc từ các khái niệm tổng quan nhất, cho đến việc giải thích, đánh giá và cuối cùng là các chi tiết kiến trúc chuyên sâu.

Mục lục

1	Tổng quan và Bản chất Toán học của Biểu diễn Tiềm ẩn	3
2	Các Cấu trúc Biểu diễn Tiềm ẩn Phổ biến	4
2.1	Góc nhìn Từ trên xuống (BEV) và Hỗ trợ Đa Phương thức	4
2.2	Biểu diễn dạng Thể tích (Voxel Features) cho 3D Occupancy	4
2.3	Biểu diễn dạng Vector (Agent & Map Tokens)	4
2.4	Tổng kết và So sánh Các Kiểu Biểu diễn	5
3	Nền tảng Lý thuyết và Động lực Học của Không gian Tiềm ẩn	5
3.1	Kiến trúc Dự đoán Kết hợp Biểu diễn (JEPA)	6
3.2	Mô hình hóa Không chắc chắn thông qua VAE	6
4	Tính Diễn giải và Giải thích Không gian Tiềm ẩn (Latent Explanation)	6
4.1	Giải thích dựa trên Tập dữ liệu Tham chiếu (Corpus-based Explanation) .	6
4.2	Sinh Mặt nạ Ngữ nghĩa (Semantic Mask Generation)	6
5	Phương pháp Đánh giá Biểu diễn Tiềm ẩn	7
5.1	Đánh giá qua Tái tạo Hình học và Thị giác (Reconstruction Metrics) . . .	7
5.2	Đánh giá Toán học về Độ chính xác của Giải thích	7
5.3	Đánh giá qua Tác vụ Nhận thức Đầu cuối (Downstream Metrics)	7
6	Triển khai Thực tế và Chi phí Tính toán	7
6.1	Độ phức tạp Bộ nhớ (VRAM Consumption)	7
6.2	Tối ưu hóa Cấu trúc Dữ liệu Truy xuất	8
7	Kỷ nguyên Hội tụ 2025-2026: Xóa bỏ Ranh giới Giữa Mô phỏng và Quyết định	8
7.1	DriveLaW: Hợp nhất Lập kế hoạch và Tạo Video	8
7.2	DriveFuture: Tiềm ẩn Cảm nhận Tương lai	8
7.3	Đổi mới Không gian: Delta-Triplane và 4D Occupancy	8
8	Những Thách thức Hiện tại (Open Challenges)	8
9	Kết luận	9

1 Tổng quan và Bản chất Toán học của Biểu diễn Tiềm ẩn

Trong các hệ thống lái xe tự động hiện đại (đặc biệt là kiến trúc End-to-End), việc xử lý trực tiếp trên không gian dữ liệu quan sát gốc o_t (gồm hàng triệu pixel từ đa camera hoặc hàng triệu điểm point cloud từ LiDAR) là bất khả thi về mặt tính toán và dễ bị ảnh hưởng bởi nhiễu ngoại cảnh (như thời tiết, ánh sáng).

Thay vào đó, hệ thống xây dựng một **Không gian Biểu diễn Tiềm ẩn (Latent Space)** $\mathcal{Z}$, nơi mỗi trạng thái tiềm ẩn $z_t \in \mathcal{Z}$ được ánh xạ thông qua hàm mã hóa (Encoder) θ :

$$z_t = E_{\theta}(o_{\leq t}) \quad (1)$$

Để một không gian tiềm ẩn có giá trị thực sự cho hệ thống tự lái (đặc biệt trong các World Models), nó không chỉ cần nén dữ liệu mà phải thỏa mãn đồng thời **6 ràng buộc đủ (Sufficiency Constraints)** sau đây:

- **1. Trừu tượng hóa dự đoán (Predictive Abstraction):** Không gian tiềm ẩn phải cô lập các yếu tố tác động đến tương lai và loại bỏ hoàn toàn các chi tiết ngẫu nhiên, nhiễu rác (stochastic noise) không liên quan (ví dụ: lá cây rơi, bóng râm thay đổi). Nói cách khác, trạng thái tiềm ẩn z_t phải đủ thông tin để dự đoán trạng thái tương lai z_{t+k} .
- **2. Trạng thái niềm tin (Belief State):** Do cảm biến xe tự hành luôn gặp hiện tượng che khuất một phần (partial observability - ví dụ xe khác khuất sau xe tải), biểu diễn tiềm ẩn phải hoạt động như một bộ nhớ tích lũy chuỗi quan sát lịch sử $o_{\leq t}$, giúp suy luận ra các vật thể đang bị che khuất dựa trên lịch sử chuyển động.
- **3. Trạng thái mô phỏng có cấu trúc (Structured Simulator State):** Không gian tiềm ẩn cần mã hóa tường minh các đối tượng vật lý (phương tiện, người đi bộ, làn đường) và tuân thủ các định luật vật lý cơ bản (động học, động lực học chất điểm).
- **4. Giao diện hành động (Action Interface):** Trạng thái tiềm ẩn phải nhạy bén với các hành động điều khiển a_t của xe (bẻ lái, phanh, tăng tốc). Cấu trúc của không gian này cần phản ánh được sự thay đổi trạng thái dưới tác động của hành động: $z_{t+1} = f(z_t, a_t)$.
- **5. Hình học lập kế hoạch (Planning Geometry):** Không gian tiềm ẩn phải hỗ trợ việc tìm kiếm và tối ưu hóa quỹ đạo (trajectory optimization) trực tiếp mà không cần giải mã ngược lại không gian ảnh pixel tốn kém thời gian.
- **6. Cơ chất bộ nhớ (Memory Substrate):** Duy trì tính nhất quán về mặt ngữ nghĩa và không gian của toàn bộ khung cảnh trong các khoảng thời gian dài (long-horizon consistency), ngăn chặn hiện tượng trôi dạt biểu diễn (drift) khi xe di chuyển quãng đường dài.

2 Các Cấu trúc Biểu diễn Tiềm ẩn Phổ biến

2.1 Góc nhìn Từ trên xuống (BEV) và Hỗ trợ Đa Phương thức

Một câu hỏi quan trọng là: Biểu diễn tiềm ẩn có hỗ trợ đa camera không? Câu trả lời là Có, và đây là thế mạnh lớn nhất của nó.

Dữ liệu hình ảnh từ camera được thu nhận dưới góc nhìn phối cảnh (Perspective View - PV). Tuy nhiên, các phương pháp hiện đại đều thiết lập một không gian tiềm ẩn chung dưới dạng Góc nhìn Từ trên xuống (Bird's Eye View - BEV). BEV cung cấp một không gian biểu diễn vật lý có thể diễn giải được, cho phép dung hợp thông tin từ nhiều góc nhìn (ví dụ: 6 camera bao quát 360 độ xung quanh xe) một cách tự nhiên mà không bị biến dạng ở các khu vực chồng lấn.

Các mô hình như BEVWorld và BEVFusion sử dụng một bộ "tokenizer đa phương thức" (multi-modal tokenizer) để phóng chiếu các đặc trưng từ nhiều camera và cả cảm biến LiDAR vào cùng một lưới BEV tiềm ẩn. Bằng cách này, toàn bộ dữ liệu đa camera được hợp nhất thành một biểu diễn duy nhất, chứa cả mật độ ngữ nghĩa của camera và cấu trúc hình học của LiDAR.

2.2 Biểu diễn dạng Thể tích (Voxel Features) cho 3D Occupancy

Khi biểu diễn BEV 2D truyền thống bị thiếu thông tin về chiều cao, các nghiên cứu hiện đại chuyển sang sử dụng Voxel Features để mô tả không gian 3D chi tiết hơn:

- **Bản chất kỹ thuật:** Các token BEV (vốn chỉ có 2 chiều x, y) được nâng cấp lên không gian 3D thông qua các lớp upsampling và các khối Swin-blocks chồng lên nhau để tạo ra các đặc trưng thể tích (Voxel). Mỗi voxel đại diện cho một vùng không gian nhỏ trong lưới 3D, chứa thông tin về xác suất chiếm chỗ (occupancy) và đặc trưng ngữ nghĩa.
- **Mục tiêu chứng minh biểu diễn:** Chất lượng được chứng minh thông qua các tác vụ reconstruction (tái tạo). Ví dụ, trong mô hình BEVWorld, đặc trưng Voxel được đưa qua bộ giải mã sử dụng kỹ thuật *ray-casting rendering* (tương tự NeRF) để phục dựng lại đám mây điểm LiDAR và hình ảnh đa cam. Nếu dữ liệu phục dựng khớp với dữ liệu gốc, không gian ẩn Voxel đã nén trọn vẹn cấu trúc hình học 3D.
- **Ứng dụng chính:** Dự đoán chiếm chỗ ngữ nghĩa (Semantic Occupancy Prediction) giúp xe hiểu được các vật thể có hình dạng bất định (như chợ tự phát, đồng cỏ nát trên đường).

2.3 Biểu diễn dạng Vector (Agent & Map Tokens)

Thay vì biểu diễn toàn bộ cảnh vật dưới dạng lưới (grid) tốn kém tài nguyên, các mô hình thế giới mới (như GenAD hay VAD) chuyển sang hướng tiếp cận *Instance-centric* (lấy thực thể làm trung tâm):

- **Agent Tokens (Token tác nhân):** Mỗi tác nhân (xe cộ, người đi bộ) được đại diện bởi một tập hợp các vector tiềm ẩn, được cập nhật từ đặc trưng BEV thông qua cơ chế *Deformable Cross-Attention*. Mục tiêu là mã hóa vị trí 3D, hướng (orientation), vận tốc và loại đối tượng để dự đoán quỹ đạo tương lai hiệu quả hơn.

- **Map Tokens (Token bản đồ):** Do các yếu tố bản đồ (vạch kẻ đường, ranh giới) thường thưa thớt (sparse), việc dùng tokens giúp giảm đáng kể lượng tính toán so với grid. Mỗi map token giải mã thành một tập hợp các điểm trong không gian BEV để định hình học làn đường.
- **Ưu điểm vượt trội:** Giúp hệ thống lập kế hoạch (planning) tập trung trực tiếp vào mối quan hệ giữa "Xe tự hành" (Ego Token) và các "Tác nhân xung quanh" (Agent Tokens) mà không phải xử lý hàng nghìn ô lưới trống, đồng thời hỗ trợ không gian ẩn quỹ đạo (Latent Trajectory Space).

2.4 Tổng kết và So sánh Các Kiểu Biểu diễn

Để hệ thống hóa lại các phương pháp đã thảo luận, Bảng 1 tóm tắt đặc điểm cốt lõi và ứng dụng của 4 kiểu biểu diễn tiềm ẩn tiêu biểu nhất trong các hệ thống xe tự hành hiện đại. Sự tiến hóa của các kiểu biểu diễn này cho thấy xu hướng dịch chuyển từ việc mô tả không gian (BEV, Voxel) sang việc mô tả thực thể và tương tác (Tokens, Graph).

Bảng 1: So sánh các kiểu biểu diễn tiềm ẩn phổ biến trong xe tự hành.

Kiểu Biểu Diễn	Bài báo Tiêu biểu	Đặc điểm Cốt lõi	Tác vụ Ứng dụng
Bird's-Eye View (BEV 2D)	LSS, BEV-Former	Biểu diễn không gian dưới dạng lưới 2D nhìn từ trên xuống. Dung hợp đa cảm biến cực tốt, cân bằng giữa tốc độ và độ chính xác.	Nhận diện vật thể 3D, Phân vùng ngữ nghĩa (Segmentation).
Voxel Features (3D Occupancy)	BEVWorld, OccFormer	Biểu diễn 3D dày đặc (voxels), giữ trọn vẹn thông tin chiều cao và cấu trúc hình học của vật thể bất định.	3D Occupancy, Tái tạo hình học cảm biến (Ray-casting).
Vectorized (Agent/Map Tokens)	GenAD, VAD, MapTR	Biểu diễn thưa thớt dạng điểm/vector. Lấy thực thể làm trung tâm, vô cùng nhẹ về dung lượng và chi phí tính toán.	Dự đoán chuyển động, Xây dựng bản đồ HD, Lập kế hoạch.
Graph-based (Đồ thị)	VectorMapNet, GNN Models	Biểu diễn không gian bằng đồ thị (Nút là thực thể, Cạnh là mối tương tác). Rất mạnh trong việc mô phỏng logic xã hội.	Dự đoán hành vi tương tác, Lập kế hoạch an toàn (Safety Planning).

3 Nền tảng Lý thuyết và Động lực Học của Không gian Tiềm ẩn

Khi biểu diễn BEV được thiết lập làm khung tham chiếu chung, hệ thống tập trung vào việc mô hình hóa sự tiến hóa của không gian này theo thời gian.

3.1 Kiến trúc Dự đoán Kết hợp Biểu diễn (JEPA)

Mô hình không nên bị ép buộc tái tạo lại toàn bộ dữ liệu ảnh gốc chứa những chi tiết nhiễu. Thay vào đó, nó sử dụng phương trình suy hao khử nhiễu mặt nạ trong không gian tiềm ẩn:

$$\min_{\theta, \phi} \|P_{\phi}(\Delta_y, E_{\theta}(x)) - sg(E_{\bar{\theta}}(y))\|_1 \quad (2)$$

Việc sử dụng sg (dừng đạo hàm) và bộ mã hóa mục tiêu thông qua Trung bình Động Hàm mũ (EMA) tạo ra quỹ đạo ổn định, ép mạng phải học động lực học không-thời gian thay vì bị suy sụp biểu diễn (representation collapse).

3.2 Mô hình hóa Không chắc chắn thông qua VAE

Trong bối cảnh giao thông, tương lai luôn chứa tính ngẫu nhiên. Mô hình GenAD giải quyết bản chất ngẫu nhiên này thông qua kiến trúc VAE, thiết lập một không gian tiềm ẩn cấu trúc để mã hóa kinh nghiệm tiên nghiệm về quỹ đạo. Mô hình ánh xạ các quỹ đạo thành một phân phối Gauss đường chéo. Trạng thái tiềm ẩn sau đó được đưa qua mạng GRU để cập nhật liên tục, cho phép hệ thống "tưởng tượng" quỹ đạo hợp lý theo các bước thời gian.

4 Tính Diễn giải và Giải thích Không gian Tiềm ẩn (Latent Explanation)

Một thách thức lớn của biểu diễn tiềm ẩn là tính "hộp đen" (black-box). Để chứng minh và diễn giải các quyết định của hệ thống trong không gian tiềm ẩn, các nghiên cứu tập trung vào hai hướng tiếp cận chính, khiến việc chứng minh trở nên dễ dàng và trực quan hơn:

4.1 Giải thích dựa trên Tập dữ liệu Tham chiếu (Corpus-based Explanation)

Phương pháp Simplex tiếp cận việc giải thích bằng cách "tái tạo" lại biểu diễn tiềm ẩn của một tình huống hiện tại thành một hỗn hợp (mixture) các biểu diễn tiềm ẩn từ các tình huống đã biết trong quá khứ (corpus). Hơn nữa, thông qua một kỹ thuật gọi là Integrated Jacobian (một dạng tổng quát hóa của Integrated Gradients trong không gian tiềm ẩn), hệ thống có thể tính toán chính xác tính đóng góp của từng đặc trưng đầu vào (từng camera, từng pixel) vào sự thay đổi trong không gian tiềm ẩn. Điều này trả lời trực tiếp cho câu hỏi: Đặc điểm nào của dữ liệu đầu vào đã khiến hệ thống tạo ra biểu diễn tiềm ẩn này?.

4.2 Sinh Mặt nạ Ngữ nghĩa (Semantic Mask Generation)

Để kiểm chứng xem không gian tiềm ẩn có thực sự hiểu thế giới hay không, một số mô hình môi trường tiềm ẩn tuần tự (sequential latent environment model) được thiết kế sao cho từ trạng thái tiềm ẩn, chúng có thể giải mã ngược lại thành các "mặt nạ ngữ nghĩa góc nhìn từ trên xuống" (semantic birdseye masks) hoặc trực tiếp thành hình ảnh. Bằng cách hiển thị các mặt nạ này cho con người, ta có thể đánh giá và giải thích chính xác hệ thống đang "suy nghĩ" về bối cảnh giao thông như thế nào trước khi ra quyết định.

5 Phương pháp Đánh giá Biểu diễn Tiềm ẩn

Việc đánh giá chất lượng của biểu diễn tiềm ẩn không thực hiện trực tiếp trên bản thân các con số của nó, mà thông qua các giới hạn đáp ứng (sufficiency constraints) và hiệu suất ở các tác vụ đầu ra.

5.1 Đánh giá qua Tái tạo Hình học và Thị giác (Reconstruction Metrics)

Trong các mô hình như BEVWorld, biểu diễn tiềm ẩn (BEV tokens) được giải mã ngược lại thành hình ảnh hoặc đám mây điểm. Lúc này, chất lượng biểu diễn được đo bằng:

- **Độ đo Chamfer (Chamfer Distance):** Đánh giá độ sai lệch của hình học 3D được tái tạo so với thực tế.
- **PSNR và FID:** Đánh giá chất lượng và độ chân thực của hình ảnh camera được tái tạo từ không gian tiềm ẩn.

5.2 Đánh giá Toán học về Độ chính xác của Giải thích

Đối với các phương pháp giải thích như SimplEx, chất lượng của việc phân rã biểu diễn tiềm ẩn được đo bằng chỉ số, cho biết mức độ chính xác của việc xấp xỉ không gian tiềm ẩn hiện tại bằng các mẫu lịch sử.

5.3 Đánh giá qua Tác vụ Nhận thức Đầu cuối (Downstream Metrics)

Nếu biểu diễn tiềm ẩn tốt, các tác vụ nối tiếp nó phải có hiệu suất cao. Các chỉ số tiêu chuẩn bao gồm:

- **mAP (mean Average Precision) và NDS (nuScenes Detection Score):** Dùng để đánh giá độ chính xác của việc phát hiện đối tượng 3D.
- **LET-3D-AP (Longitudinal Error Tolerant 3D Average Precision):** Một chỉ số mới khoan dung hơn với các sai số về chiều dọc do giới hạn ước lượng chiều sâu của camera, giúp đánh giá công bằng hơn đối với các biểu diễn chỉ dựa trên camera.

6 Triển khai Thực tế và Chi phí Tính toán

Mặc dù mang lại hiệu suất nhận thức vượt trội, việc đưa các không gian biểu diễn tiềm ẩn (đặc biệt là 3D Occupancy và World Models) lên phần cứng thực tế của xe tự hành (như NVIDIA DRIVE Orin) gặp phải rào cản lớn về chi phí tính toán và bộ nhớ.

6.1 Độ phức tạp Bộ nhớ (VRAM Consumption)

Khác với BEV chỉ tiêu tốn bộ nhớ theo bình phương độ phân giải $\mathcal{O}(H \times W)$, biểu diễn thể tích (Voxel Features) đòi hỏi chi phí không gian lên tới $\mathcal{O}(H \times W \times Z)$. Điều này dễ dàng dẫn đến hiện tượng tràn bộ nhớ máy tính tính toán (Out-Of-Memory) nếu không có các kỹ thuật cắt tỉa (pruning) hoặc lượng tử hóa (quantization) mạng neural.

6.2 Tối ưu hóa Cấu trúc Dữ liệu Truy xuất

Để duy trì độ trễ ở mức an toàn (thường yêu cầu hệ thống phản hồi dưới 30ms mỗi khung hình), việc tối ưu hóa truy xuất dữ liệu trong không gian tiềm ẩn là bắt buộc. Đối với các biểu diễn thưa thớt như Map Tokens hay Agent Tokens, hệ thống hiếm khi quét toàn bộ ma trận đặc trưng. Thay vào đó, việc kết hợp các mảng động (dynamic arrays) hoặc cơ chế tìm kiếm dựa trên cây (như AVL trees, Red-Black trees) được ứng dụng mạnh mẽ để lập chỉ mục (indexing) không gian 3D một cách tối ưu. Nhờ vậy, bộ lập kế hoạch có thể truy vấn nhanh chóng các đặc trưng tiềm ẩn của tác nhân lân cận để ra quyết định mà không làm nghẽn cổ chai hệ thống.

7 Kỷ nguyên Hội tụ 2025-2026: Xóa bỏ Ranh giới Giữa Mô phỏng và Quyết định

Cho đến đầu năm 2025, các kiến trúc end-to-end tự lái phần lớn vẫn tách biệt: Mô hình thế giới "tưởng tượng" bối cảnh tương lai trong không gian tiềm ẩn, sau đó chuyển kết quả cho bộ lập kế hoạch. Sự dịch thuật này gây ra xung đột tối ưu hóa.

7.1 DriveLaW: Hợp nhất Lập kế hoạch và Tạo Video

DriveLaW tích hợp trực tiếp không gian biểu diễn tiềm ẩn từ công cụ tạo sinh video vào sâu bên trong bộ lập kế hoạch quỹ đạo khuếch tán. Biểu diễn tiềm ẩn chứa đựng sự hiểu biết phong phú về mặt cấu trúc-không-thời gian được tiêm thẳng vào bộ lập kế hoạch, đảm bảo tính nhất quán giữa bối cảnh sinh ra và quỹ đạo điều khiển được đưa ra.

7.2 DriveFuture: Tiềm ẩn Cảm nhận Tương lai

Thay vì dự đoán mù quáng, DriveFuture áp đặt điều kiện cho việc ra quyết định hiện tại thông qua các trạng thái thế giới tiềm ẩn tương lai. Trạng thái tiềm ẩn dự đoán được sử dụng để tinh chỉnh lại chính biểu diễn tiềm ẩn ban đầu (thông qua cross-attention), ép buộc hệ thống phải tính toán "tầm nhìn xa định hướng quy hoạch" (planning-oriented foresight) ngay từ bước đầu tiên.

7.3 Đổi mới Không gian: Delta-Triplane và 4D Occupancy

Thay vì giải mã lại toàn bộ trạng thái không gian ở mọi khung hình tương lai, các phương pháp mới như Delta-Triplane chỉ tập trung vào việc mô hình hóa "các khoảng biến thiên" (triplane deltas) trong không gian tiềm ẩn 3D chiếm chỗ (Occupancy). Điều này giảm tải gánh nặng tính toán kiến trúc, mang lại hiệu quả triển khai khổng lồ.

8 Những Thách thức Hiện tại (Open Challenges)

Mặc dù kỷ nguyên hội tụ đã mang lại những bước tiến dài, hệ thống biểu diễn tiềm ẩn cho xe tự hành vẫn đang đối mặt với các vấn đề chưa được giải quyết triệt để:

- **Hiện tượng Ảo giác (Hallucination) trong Mô hình Thế giới:** Khi sử dụng các mô hình tạo sinh (như GenAD) để "tưởng tượng" quỹ đạo tương lai, mô hình

có thể tự sinh ra các thực thể không hề tồn tại trên đường hoặc dự đoán sai lệch các quy luật vật lý cơ bản, dẫn đến những quyết định phanh gấp (phantom braking) nguy hiểm.

- **Sự dịch chuyển Miền dữ liệu (Domain Gap):** Không gian biểu diễn tiềm ẩn thường bị suy giảm chất lượng mạnh khi xe di chuyển từ khu vực huấn luyện (ví dụ: trời nắng, đô thị) sang các miền dữ liệu mới (mưa bão, sương mù dày đặc, hoặc đường ngoại ô không có vạch kẻ). Việc đảm bảo tính bền vững (robustness) của Latent Space dưới điều kiện nhiễu là một bài toán lớn.
- **Lỗi Tích lũy Dài hạn (Long-horizon Error Accumulation):** Ở các tác vụ dự đoán chuỗi hành động dài, sai số ở các trạng thái tiềm ẩn ban đầu z_t sẽ bị khuếch đại lên nhiều lần khi truyền đến z_{t+k} , khiến không gian bộ nhớ (Memory Substrate) bị trôi dạt (drift) và mất tính nhất quán với trạng thái thực tế của môi trường.

9 Kết luận

Biểu diễn tiềm ẩn (Latent Representation) không chỉ là một công cụ nén dữ liệu mà là cơ chế nhận thức cốt lõi của xe tự hành. Bằng cách thiết lập khung biểu diễn trong không gian BEV kết hợp với các cấu trúc tiên tiến như Voxel Features và Agent/Map Tokens, hệ thống có thể dễ dàng dung hợp dữ liệu từ đa camera và LiDAR. Chất lượng của các biểu diễn này hoàn toàn có thể được đánh giá và giải thích thông qua các công cụ toán học như Integrated Jacobian, so khớp phân phối, hoặc sinh mặt nạ ngữ nghĩa (semantic masks). Việc dung hợp giữa Biểu diễn Tiềm ẩn, Mô hình Thế giới Động lực học và quy trình lập kế hoạch chính là chìa khóa để giải quyết bài toán "kịch bản hiếm" (long-tail edge cases) và tiến tới tự lái cấp độ cao.