

Experiment	Mục đích chi tiết	Cách thực hiện & Metrics	Kết quả kỳ vọng	Bài báo tham khảo
1. Đánh giá khối Feature Extraction & Fusion				
Đánh giá vai trò của nhánh Optical Flow	1. Chứng minh dòng quang học thực sự đóng góp vào dự đoán tương lai, không phải do mạng tự nội suy 2. Khẳng định sự phân tách và bù trừ đặc thù giữa luồng Tĩnh và Động	Chạy Ablation với 4 biến thể: 1. Full Model 2. Static-only 3. Flow-only 4. Random Flow (Thay Flow bằng nhiễu ngẫu nhiên) Đo lường bằng 2 bộ Metrics: - Nội tại: Cosine Similarity giữa $\hat{z}_{t+1}$ (dự đoán bởi Predictor) và z^*_{t+1} (thực tế từ Frozen ViT) trên các video chuyển động mạnh. - Linear Probe: Đo mAP trên vật thể động (xe máy, người đi bộ) và mIoU phân vùng cảnh tĩnh (vạch kẻ đường, vỉa hè).	1. Về Dự đoán tương lai: Full Model > Static-only ≈ Random Flow (chứng tỏ nhiễu không có tác dụng, bắt buộc phải có Flow thật). 2. Về Downstream Tasks: - Flow-only: Nhận diện rất tốt vật thể động (mAP cao) nhưng mất nhận thức không gian (mIoU thấp). - Static-only: Ngược lại, rất giỏi giữ ngữ cảnh tĩnh nhưng bỏ sót chuyển động. - Full Model: Đạt điểm tối ưu nhất ở cả 2 tác vụ nhờ cơ chế kết hợp hoàn hảo.	Baseline: https://github.com/princeton-vl/RAFT FlowFormer++ Code: https://github.com/XiaoyuShi97/FlowFormerPlusPlus.git Paper: https://arxiv.org/pdf/2303.01237
Cross-Attention	Chứng minh Cross-Attention + Gate vượt trội hơn các phép tính nối/cộng đặc trưng thông thường.	1. Phân tích bảo toàn tri thức (CKA): Tính $CKA(z_{fused}, e_{static})$ trên tập video tĩnh (chờ đèn đỏ, kẹt xe đứng im). 2. Phân tích trực quan (Attention map): Trích xuất và vẽ ma trận trọng số (Attention Weights) của lớp Cross-Attention khi xem video có xe máy tạt đầu	1. Về bảo toàn tri thức: CKA duy trì mức > 0.90, chứng tỏ cơ chế Zero-Gate giúp mô hình chống lại hiện tượng quên ngay cả khi được nội suy thêm dữ liệu mới. 2. Về khả năng chất lọc: Trọng số Attention sẽ tự động sáng tập trung vào các chủ thể đang di chuyển động lực học cao (xe máy luồn lách) và phớt lờ các vùng tĩnh.	https://arxiv.org/abs/1905.00414
2. Đánh giá khối Latent Factorization & Confounder GRU				
Độc lập tuyến tính (Orthogonality)	Đảm bảo không gian biểu diễn của Task và Ngoại sinh (Exogenous) hoàn toàn tách biệt, không đè lên nhau.	Đo norm của ma trận hiệp phương sai chéo. - Metric: $L_{orth_norm} = \ Z_{task}^T \cdot Z_{exol}\ _F^2 / d$	$L_{orth_norm} < 0.01$ sau khi hội tụ.	https://arxiv.org/abs/1608.06019

Experiment	Mục đích chi tiết	Cách thực hiện & Metrics	Kết quả kỳ vọng	Bài báo tham khảo
Độc lập phi tuyến (MINE)	Chứng minh z_exo không hề chứa bất kỳ thông tin nào rò rỉ từ hành động (action a_t).	Dùng mạng Neural (Critic) để ước lượng Mutual Information (MI). - Metric 1: $I(z_exo; a_t)$ - Metric 2: $I(z_task; a_t)$ Chạy nhiều seed hoặc đối chiếu thêm bằng CLUB (upper-bound estimator) để tránh kết luận độc lập chỉ vì estimator yếu (MINE: lower-bound style estimation)	$I(z_exo; a_t) < 0.05$ nats. $I(z_task; a_t) > 0.5$ nats. (Sự bất đối xứng)	MINE: https://arxiv.org/abs/1801.04062 CLUB: https://arxiv.org/pdf/2006.12013https://github.com/Linear95/CLUB
Counterfactual Variance Ratio	Chứng minh backdoor (nhiều từ môi trường) đã bị chặn lại khi nội suy hành động (do-calculus).	Cố định U_t (Confounder), quét qua 4 loại hành động (thắng, tăng tốc, rẽ trái, phải). - Metric: $Ratio = Var(\hat{z}_{t+1} do(a)) / Var(\hat{z}_{t+1} a, U)$	$Ratio < 0.5$ (Nhiều đã bị U_t hấp thụ trên 50%). So sánh cùng với baseline $U_t = 0$ (random noise) ở cùng công thức. Nếu $Ratio(U_t \text{ thật}) \ll Ratio(U_t=0 \text{ random})$, thì ta có thể chứng minh U_t hấp thụ confounder tốt hơn nhiều ngẫu nhiên	https://arxiv.org/abs/2010.04296
Phân tích ngữ nghĩa U_t	Chứng minh Confounder (U_t) học được ý định của tác nhân khác (ví dụ: xe tạt đầu), không phải là vector nhiễu.	Đóng băng model, chỉ train 1 lớp Linear (Probe) dự đoán 4 loại hành vi từ vector U_t . - Metric: Độ chính xác (Accuracy) và Recall của lớp Cut-in - So sánh với Baseline $U=0$	Accuracy cao hơn model $U=0$ ít nhất 10%. Cut-in recall > 60%.	Causal RL Survey / MDP Confounders
3. Đánh giá Predictor & Khả năng giữ tri thức				
Kiểm tra Representation Collapse	Đảm bảo embedding không bị collapse thành vector hằng số (lỗi phổ biến khi train SSL)	Đo độ lệch chuẩn (std) của embedding sinh ra qua từng batch. - Metric: $variance = mean(max(0, 1.0 - std(z)))$	$variance < 0.1$ (gần 0). Không có chiều nào có $std = 0$.	https://arxiv.org/abs/2105.04906
Generalization trên tập OOD	Predictor thực sự học được cách suy luận, không phải học vẹt (memorize) các cảnh trong tập train.	Cho mô hình đoán trên các video hoàn toàn mới (khác loại cảnh). - Metric: Cosine Similarity giữa $\hat{z}$ (đoán) và z^* (thực). - So sánh với Mean-Predictor (baseline đoán vector trung bình của tập train).	$Cosine > 0.85$. Cách biệt > 0.20 so với Mean-Predictor.	https://arxiv.org/abs/2301.08243
Backward Transfer (BWT)	Chứng minh việc train thêm nhánh Causal/Motion không làm hỏng kiến thức gốc của V-JEPA2.	Đánh giá V-JEPA2 trên tập OpenScene/Kinetics-400 trước khi train Camo-JEPA, sau đó đánh giá lại trên cùng tập dữ liệu với Camo-JEPA. - Metric: $BWT = Acc_after - Acc_before$ (before là CaMo-JEPA trước train hay còn là VJEPA2) + $BWT < 0$: xảy ra forgetting. + $BWT \approx 0$: kiến thức gốc được bảo toàn. + $BWT > 0$: có positive backward transfer. So sánh mức độ bảo toàn kiến thức với các phương pháp Continual Learning như EWC và LwF.	$BWT \geq -0.02$ (Gần như không bị quên).	https://arxiv.org/abs/1706.08840

Experiment	Mục đích chi tiết	Cách thực hiện & Metrics	Kết quả kỳ vọng	Bài báo tham khảo
Trade-off Plasticity-Stability	Tìm trọng số L_recon (λ_2) tối ưu nhất giữa việc học mới (Motion) và giữ cũ (Static).	Quét λ_2 qua 5 giá trị. Vẽ biểu đồ phân tán (Scatter plot) 2D: - Trục X: CKA(z_fused, e_static) (Độ giữ gốc) - Trục Y: Độ tương quan chuyển động (Độ học mới)	Camo-JEPA nằm trên đường biên Pareto (Pareto frontier)	https://arxiv.org/abs/1703.04200
Masking Ablation & Region-based Similarity	Tải lại chính xác vị trí patch để vẽ heatmap, hiển thị khung hình dự đoán, và tính Cosine Similarity theo vùng bị che	So sánh 2 biến thể: Random Masking và Motion-weighted Masking - Cách thực hiện: Tải lại chính xác vị trí patch bị che lên khung hình gốc để vẽ heatmap. - Metric: Đo Cosine Similarity cục bộ chỉ trên các vùng bị che, phân rã điểm số theo các vùng động vs vùng tĩnh.		https://arxiv.org/pdf/2301.08243
CKA tổng thể trên cảnh tĩnh	Chứng minh final output của Camo-JEPA không bị biến dạng so với V-JEPA2 gốc	Sử dụng thư viện torch-cka tính CKA(z_camo, z_vjepa2) trên tập video lái xe chờ đèn đỏ, đường trống	CKA tổng thể > 0.90 (Giữ được >90% cấu trúc).	https://arxiv.org/abs/1905.00414 https://github.com/AntixK/PyTorch-Model-Compare
4. Phân tích Layer-wise/ Visualization & So sánh mô hình tổng thể				
Linear Probing mAP	So sánh sức mạnh nhận thức tổng thể của Camo-JEPA với các Foundation Models khác trong bài toán Driving hoặc giữa bật tắt các nhánh trong CaMo-JEPA	Đóng băng toàn bộ kiến trúc, chỉ train 1 lớp Linear Head trên tập NuScenes/BDD100K. So với V-JEPA2, DINO-v2, BEVFormer.	Camo-JEPA vượt V-JEPA2 3-5% mAP. Vượt trội DINO-v2 ở AP_near.	https://arxiv.org/abs/2111.06377
5. Hiệu Quả Thuật Toán (Compute & GPU Efficiency)				
Training Cost (Backward Time & Params)	Chứng minh đóng băng (Freeze) ViT Backbone giúp mô hình cực kỳ nhẹ khi huấn luyện so với các mô hình full fine-tune.	Đo thời gian Backward Pass bằng torch.autograd.profiler (ms). Đếm số tham số requires_grad=True	Backward time giảm $\geq 70\%$. Trainable params chiếm ~15-20%.	
Peak Memory & FLOPs	Đảm bảo mô hình chạy ổn định trên GPU phổ thông và có khả năng deploy thực tế	Đo đỉnh RAM GPU trong lúc train (batch=16) bằng torch.cuda.max_memory_allocated(). Đo FLOPs bằng fvcare	Peak Memory < 28GB	https://github.com/facebookresearch/fvcore
6. Trực quan hóa				
Latent Trajectory (UMAP)	Xem quỹ đạo của z_task và z_exo khi có sự kiện (ví dụ xe tạt đầu) diễn ra theo thời gian	Nén chuỗi nhiều frames (khoảng 30) embedding xuống 2D bằng UMAP. Đánh dấu mốc t=0 (lúc sự kiện bắt đầu). Vẽ biểu đồ màu gradient theo thời gian	Output: 2D Trajectory Plot - Đường vẽ của z_task sẽ gãy góc 90 độ tại t=0. - Đường vẽ của z_exo sẽ là một cục vón cục đứng im.	https://github.com/lmcinnes/umap

Experiment	Mục đích chi tiết	Cách thực hiện & Metrics	Kết quả kỳ vọng	Bài báo tham khảo
Counterfactual Intervention Visuals	Khi cố tình thay đổi hành động (do-calculus), bối cảnh nền (trời, đường) phải đứng yên, chỉ có vật thể bị tác động di chuyển, tức chứng minh mô hình thực sự hiểu nhân-quả bằng cách tự sinh ra ảo giác giả lập khi ta đổi lệnh vô lăng	Giữ nguyên bối cảnh (z_exo, U_t). Thay đổi input hành động a_t thành bẻ lái trái/phải. Đưa vào một mạng mỏng (ConvTranspose) giải mã ngược ra hình ảnh RGB	Output: Decoded Videos (Side-by-side) Mắt thường thấy rõ: Bầu trời và cây cối đứng im, chỉ có xe là ngả hướng theo đúng lệnh điều khiển mới.	https://arxiv.org/abs/2010.04296